

MÉMOIRE DE FIN D'ÉTUDES
Pour l'obtention du Master en
Finance, Actuariat et Data Science

**L'APPORT DE L'INTELLIGENCE ARTIFICIELLE
DANS LA PRÉVISION BUDGÉTAIRE**

Cas du Ministère de la Justice du Maroc

Réalisé par :

ABBARI Fatima Ezzahraa

Encadré par :

Pr. DAKKON Mohamed, Professeur à la FSJES de Tétouan

M. ZABARATOU Iliass, Encadrant professionnel



Table des matières

Remerciements	4
Dédicace	5
Résumé	6
Abstract	7
Table des figures	8
Liste des tableaux	9
Liste des acronymes	10
Introduction générale	11
Contexte et Problématique	11
Objectifs de la Recherche	11
Méthodologie	12
Chapitre 1 : Le Ministère de la Justice	13
1.1 Historique et missions	13
1.1.1 Évolution institutionnelle	13
1.1.2 Missions et attributions	13
1.2 Organisation	14
1.2.1 Services centraux	14
1.2.2 Services déconcentrés	15
1.3 La Direction du Budget	16
1.3.1 Composition et positionnement	16
1.3.2 Fonctions et interfaces	17
1.3.3 La Division de Prévision et de Programmation Financière	18
1.4 Enjeux et objectifs du mémoire	19
1.4.1 Enjeux du projet	19
1.4.2 Objectifs de la recherche	20
1.4.3 Conclusion du chapitre	21
Chapitre 2 : La gestion budgétaire au Ministère de la Justice	22
2.1 Le budget du Ministère	22
2.1.1 Composantes du budget	22
2.1.2 Dépenses et recettes du budget général	23
2.2 Le cadre juridique de la gestion budgétaire	24

2.2.1 Les apports de la réforme	24
2.2.2 La nomenclature budgétaire	25
2.2.3 Les programmes budgétaires	25
2.2.4 Le cycle de préparation du PLF	26
2.3 L'exécution budgétaire	27
2.3.1 Crédits d'engagement et crédits de paiement	27
2.3.2 Les quatre phases de la dépense	28
2.3.3 Outils de suivi : GID et morasse	29
2.4 La prévision budgétaire	29
2.4.1 Sources de complexité	29
2.4.2 Limites des méthodes actuelles	30
2.4.3 Vers l'intelligence artificielle	31
Chapitre 3 : Fondements théoriques du Machine Learning appliqué à la prévision budgétaire	33
3.1 Prévision budgétaire	33
3.1.1 Les défis spécifiques	33
3.1.2 Pourquoi le Machine Learning	36
3.1.3 Limites des approches classiques de prévision	37
3.2 Apprentissage supervisé	38
3.2.1 Généralisation	38
3.2.2 Le compromis biais-variance	38
3.2.3 Surapprentissage et robustesse	39
3.3 Les modèles retenus	40
3.3.1 Modèles de référence (benchmarks naïfs)	40
3.3.2 Ridge (régularisation)	41
3.3.3 Méthodes d'ensemble (XGBoost)	42
3.3.4 Couche de détection d'anomalies	43
3.3.5 Justification des modèles écartés	44
3.4 La validation rigoureuse	45
3.4.1 Les données temporelles	45
3.4.2 Validation walk-forward	46
3.4.3 Risque de data leakage	47
3.4.4 Prévision directe vs roulante	47
3.4.5 Évaluation des modèles	48
3.5 Synthèse du chapitre	49
Chapitre 4 : Construction du modèle prédictif et détection d'anomalies	50
Vue d'ensemble du processus	50
4.1 Présentation et construction des données	52

4.1.1 Source et périmètre des données	52
4.1.2 Construction du jeu de données	52
4.1.3 Statistiques descriptives	53
4.2 Variables utilisées pour la prédiction	55
4.2.1 Variable cible (taux T4)	56
4.2.2 Variables explicatives et justification du choix	56
4.2.3 Encodage des variables catégorielles	57
4.3 Modèles de prédiction testés	58
4.3.1 Référence naïve (moyenne historique, lag T4)	58
4.3.2 Modèle linéaire régularisé	58
4.3.3 Modèle à arbres boostés (XGBoost)	59
4.4 Métriques et protocole d'évaluation	59
4.4.1 RMSE et erreur moyenne	60
4.4.2 Validation croisée walk-forward	60
4.4.3 Évaluation par catégorie budgétaire	60
4.5 Modèles retenus et résultats	61
4.5.1 Résultats globaux par modèle	61
4.5.2 Spécialisation par catégorie : Investissement / Matériel / Personnel	61
4.5.3 Stabilité per-fold et robustesse par catégorie	62
4.5.4 Prévisions T4 2025 et écarts observés	64
4.5.5 Amélioration post-validation : optimisation du modèle Matériel	64
4.5.6 Synthèse des optimisations : décisions méthodologiques et impact em- pirique	66
4.6 Détection d'anomalies	68
4.6.1 Définition d'une anomalie d'exécution	69
4.6.2 Méthode : z-score sur l'historique T2 par ligne	69
4.6.3 Anomalies identifiées sur l'exercice 2025	69
4.7 Synthèse, limites et conclusion	70
Chapitre 5 : Du modèle à l'outil, le système d'alerte précoce	73
5.1 Cahier des charges et choix de conception	73
5.2 Architecture du système	75
5.3 Fonctionnalités du tableau de bord interactif	76
5.4 Apports opérationnels et perspectives	78
Conclusion générale	80
Principaux résultats	80
Apports du travail	80
Limites	81
Perspectives	81

Remerciements

Au terme de ce travail, je tiens à exprimer ma sincère gratitude envers toutes les personnes qui ont contribué, de près ou de loin, à sa réalisation.

Je remercie en premier lieu **Monsieur Iliass Zabaratou**, mon encadrant professionnel, pour m'avoir guidé dans la définition du sujet de ce mémoire et pour m'avoir accordé sa confiance tout au long du stage.

Mes remerciements s'adressent également au **Professeur Mohamed Dakkon**, coordinateur du Master Finance, Actuariat et Data Science et encadrant académique de ce travail, pour son soutien, ses orientations et sa disponibilité.

J'adresse mes sincères remerciements aux cadres et professionnels du bureau, et en particulier à **Monsieur Bilal Khanfoud**, dont l'aide a été déterminante à plusieurs étapes de ce travail, ainsi qu'à **M. Zakaria** et **Mme Kaoutar**, qui m'ont guidé dès le premier jour et ont veillé à ce que mon intégration se déroule dans les meilleures conditions. Mes remerciements vont également à l'ensemble de l'équipe du bureau pour leur accueil et leurs conseils tout au long du stage.

Enfin, je remercie l'ensemble du corps enseignant du Master Finance, Actuariat et Data Science de la FSJES de Tétouan pour la qualité de la formation dispensée, ainsi que ma famille pour son soutien indéfectible.

Dédicace

*À mes parents, à mon frère et à mes amis,
pour leur soutien sans faille tout au long de ce parcours.*

Je dédie ce travail.

Résumé

Ce mémoire examine dans quelle mesure les approches de *Machine Learning* peuvent améliorer la précision de la prévision budgétaire au sein du Ministère de la Justice du Maroc, par rapport aux méthodes statistiques classiques.

La dépense publique marocaine est encadrée depuis 2015 par la Loi Organique relative à la Loi de Finances (LOF 130-13), qui impose une budgétisation par la performance et une programmation triennale. Dans ce contexte, la fiabilité des prévisions de crédits constitue un enjeu institutionnel majeur : un écart important entre prévision et exécution expose le ministère à des critiques parlementaires et à des observations de la Cour des Comptes.

À partir d'un jeu de données trimestrielles reconstitué à partir des morasses budgétaires annuelles et des rapports de la Trésorerie Générale du Royaume (2020–2025, 109 lignes budgétaires), nous évaluons quatre modèles : une moyenne historique et un décalage annuel (benchmarks), une régression linéaire régularisée (Lasso puis Ridge après validation), et un algorithme de gradient boosting (XGBoost). La validation repose sur un protocole *walk-forward* à fenêtre expansive (4 folds sur 2022–2025), conforme à la contrainte de causalité temporelle. Un module de détection d'anomalies basé sur le score z complète le dispositif en signalant les lignes en sous-exécution anormale en cours d'exercice.

Les résultats montrent que les modèles de Machine Learning, et en particulier XGBoost, offrent des gains de précision substantiels par rapport aux benchmarks, tout en permettant une interprétabilité opérationnelle grâce aux importances de variables. Ces résultats sont intégrés dans un tableau de bord interactif développé sous Power BI, mis à disposition de la Division de la Prévision et de la Programmation Financière de la Direction du Budget.

Mots-clés : prévision budgétaire, Machine Learning, Lasso, Ridge, XGBoost, LOF 130-13, Ministère de la Justice, walk-forward, détection d'anomalies.

Abstract

This thesis investigates whether Machine Learning approaches can improve the accuracy of budget execution forecasting at the Moroccan Ministry of Justice, compared to classical statistical methods.

Moroccan public expenditure has been governed since 2015 by the Organic Finance Law (LOF 130-13), which introduced performance-based budgeting and a three-year programming framework. In this context, the reliability of budget forecasts has become a major institutional challenge : significant deviations between forecasts and actual execution expose the Ministry to parliamentary scrutiny and Court of Accounts observations.

Using a quarterly dataset reconstructed from annual budget documents (*morasses budgétaires*) and Treasury General reports (2020–2025, 109 budget lines), we evaluate four models : a historical mean and an annual lag (benchmarks), a regularized linear regression (Lasso, then Ridge after validation), and a gradient boosting algorithm (XGBoost). Validation follows a walk-forward protocol with an expanding window (4 folds over 2022–2025), strictly respecting temporal causality. A Z-score anomaly detection module complements the system by flagging budget lines with abnormal under-execution during the fiscal year.

Results show that Machine Learning models, particularly XGBoost, achieve substantial accuracy gains over the benchmarks while maintaining operational interpretability through variable importance scores. These results are integrated into an interactive Power BI dashboard made available to the Financial Forecasting and Programming Division of the Ministry’s Budget Directorate.

Keywords : budget forecasting, Machine Learning, Lasso, Ridge, XGBoost, LOF 130-13, Ministry of Justice, walk-forward validation, anomaly detection.

Table des figures

1	Organigramme du ministère de la Justice (source : Décret n° 2.22.400).	15
2	Structure de la Direction du Budget du ministère de la Justice.	17
3	Composantes du budget du Ministère de la Justice.	23
4	Extrait de la morasse budgétaire du Ministère de la Justice (exercice 2024).	26
5	Le cycle de préparation du Projet de Loi de Finances (PLF) au Maroc. <i>Note : le cycle débute en réalité dès mars par la circulaire du Chef du gouvernement aux ministères (LOF, art. 47) ; la phase Avril–Mai correspond à la soumission formelle des propositions au MEF.</i>	27
6	Le cycle des dépenses publiques : engagement, liquidation, ordonnancement et paiement.	28
7	Les quatre familles du Machine Learning.	34
8	Cycle de fonctionnement d'un projet de Machine Learning : de la collecte des données au déploiement, avec itérations d'amélioration.	36
9	Profil saisonnier du taux d'exécution — Dépenses d'Investissement (2020–2025).	54
10	Profil saisonnier du taux d'exécution — Dépenses de Matériel (2020–2025).	55
11	Profil saisonnier du taux d'exécution — Dépenses de Personnel (2020–2025).	55
12	Taux d'exécution réels vs prévus par XGBoost — catégorie Investissement (folds 2022–2025).	64
13	Page 1 du tableau de bord : synthèse prédictive et exploration par ligne. La page articule cinq cartes KPI stratégiques (haut), deux graphiques linéaires de prévisions T4 2025 par catégorie (Investissement via XGBoost, Matériel via Ridge), une comparaison agrégée réel/direct/rolling par type de budget, une table de synthèse et des filtres dynamiques sur le programme et la région.	77
14	Page 2 du tableau de bord : détection d'anomalies et contexte historique. La page recense les lignes signalées par le module statistique (table centrale : intitulé, catégorie, z-score T2, label de sévérité) et les met en perspective via un panneau de <i>small multiples</i> retraçant l'évolution du taux T2 sur six exercices (2020–2025) pour chaque ligne anormale.	78

Liste des tableaux

1	Comparaison des méthodes classiques et des approches de Machine Learning.	37
2	Schéma de la validation croisée k -fold (exemple : Groupe 2 = test).	45
3	Protocole de validation walk-forward à fenêtre expansive (2022–2025).	46
4	Volumétrie du jeu de données.	52
5	Statistiques du taux d'exécution par trimestre (toutes catégories, 2020–2025).	53
6	Statistiques du taux d'exécution T4 par catégorie budgétaire.	54
7	Variables retenues pour la prévision du taux d'exécution T4.	57
8	Performance globale des quatre modèles (moyenne sur les 4 folds et les 3 catégories).	61
9	RMSE moyen par catégorie de dépense (4 folds).	62
10	Stabilité par fold : RMSE de Lasso, XGBoost et moyenne historique, par année et catégorie.	63
11	Impact de l'optimisation du modèle Matériel : Lasso + StandardScaler vs Ridge + RobustScaler + line_volatility.	65
12	Synthèse des optimisations appliquées au pipeline de prédiction.	67
13	Évolution de la performance (RMSE moyen) au cours des optimisations.	68
14	Anomalies d'exécution détectées sur l'exercice 2025.	70

Liste des acronymes

IA	Intelligence Artificielle
ML	Machine Learning
LOF	Loi Organique relative à la Loi de Finances
MJ	Ministère de la Justice
TGR	Trésorerie Générale du Royaume
GID	Gestion Intégrée de la Dépense
PLF	Projet de Loi de Finances
RMSE	Root Mean Squared Error
MAE	Mean Absolute Error
MAPE	Mean Absolute Percentage Error

Introduction générale

La prévision budgétaire est au cœur de la gouvernance financière publique. Pour un ministère comme celui de la Justice du Maroc, anticiper avec précision l'exécution des crédits n'est pas un exercice formel : c'est une condition de cohérence entre les ambitions programmatiques et les capacités réelles de dépense. Pourtant, malgré les progrès introduits par la réforme de la Loi Organique relative à la Loi de Finances (LOF 130-13), les écarts entre prévisions et réalisations demeurent significatifs, notamment pour les dépenses d'investissement.

Face à ce constat, les approches de *Machine Learning* offrent une piste prometteuse. En exploitant des structures non linéaires, en mutualisant l'information entre lignes budgétaires et en s'adaptant aux données courtes, ces méthodes pourraient combler les limites des outils statistiques classiques utilisés jusqu'ici.

Contexte et Problématique

Depuis l'entrée en vigueur de la LOF 130-13 en 2015 et sa mise en œuvre progressive jusqu'en 2020, le cadre budgétaire marocain a profondément évolué. La budgétisation par la performance, la programmation triennale et l'obligation de sincérité budgétaire (article 10) ont renforcé les exigences en matière de fiabilité des prévisions. Dans ce contexte, un écart important entre prévision et exécution expose le ministère à des critiques parlementaires et à des observations de la Cour des Comptes.

Le Ministère de la Justice présente par ailleurs des caractéristiques spécifiques qui compliquent la prévision : une masse salariale rigide représentant plus de 70 % des dépenses de fonctionnement, des dépenses d'investissement fortement concentrées sur le dernier trimestre, et une nomenclature budgétaire décomposée en plus d'une centaine de lignes hétérogènes.

C'est dans ce contexte que s'inscrit la problématique de ce mémoire :

Dans quelle mesure les approches de Machine Learning peuvent-elles améliorer la précision de la prévision de l'exécution budgétaire au Ministère de la Justice du Maroc, par rapport aux méthodes statistiques classiques ?

Objectifs de la Recherche

Ce travail poursuit quatre objectifs complémentaires :

1. **Analyser** le cadre institutionnel et budgétaire du Ministère de la Justice, afin d'identifier les facteurs qui commandent l'exécution des crédits.

2. **Construire** un jeu de données trimestrielles fiable, reconstitué à partir des morasses budgétaires annuelles et des rapports de la Trésorerie Générale du Royaume (2020–2025).
3. **Évaluer** quatre modèles de prévision – deux benchmarks classiques, une régression linéaire régularisée (Lasso puis Ridge après validation) et un algorithme XGBoost – selon un protocole de validation *walk-forward* rigoureux.
4. **Déployer** les résultats dans un tableau de bord interactif Power BI, opérationnel pour la Direction du Budget.

Méthodologie

La démarche adoptée articule trois composantes :

Une phase de contextualisation (chapitres 1 et 2) : description de l’institution, de son budget et du cadre juridique de la gestion budgétaire. Cette étape permet d’identifier les variables explicatives pertinentes et les contraintes propres aux données disponibles.

Une phase théorique (chapitre 3) : présentation des fondements du Machine Learning appliqué à la prévision de séries temporelles courtes. Sont détaillés : le compromis biais-variance, les modèles retenus (régression linéaire régularisée — Lasso puis Ridge — et XGBoost), les benchmarks de référence, le module de détection d’anomalies par score z , et le protocole de validation *walk-forward* à fenêtre expansive.

Une phase empirique (chapitre 4) : construction du jeu de données, entraînement et évaluation des modèles, analyse des résultats par indicateurs d’erreur (RMSE, MAE, MAPE).

Une phase applicative (chapitre 5) : conception, développement et évaluation du système de pilotage budgétaire – tableau de bord interactif Power BI intégrant les prévisions et les alertes d’anomalies, déployé pour la Direction du Budget.

Structure du mémoire : Le chapitre 1 présente le Ministère de la Justice. Le chapitre 2 décrit la gestion budgétaire et ses contraintes. Le chapitre 3 pose les fondements théoriques des modèles utilisés. Le chapitre 4 expose la mise en œuvre empirique et les résultats obtenus. Le chapitre 5 détaille la conception et l’évaluation du système de pilotage.

Chapitre 1 : Le Ministère de la Justice

Tout projet d'optimisation budgétaire commence par comprendre l'institution dont on pilote les crédits. Ce chapitre retrace l'évolution du Ministère de la Justice depuis 1955, décrit ses missions, et présente son organisation. Une attention particulière est portée à la Direction du Budget – interlocuteur direct de cette étude.

1.1 Historique et missions

1.1.1 *Évolution institutionnelle*

Le ministère de la Justice occupe une place singulière dans l'architecture institutionnelle marocaine. Héritier d'une tradition juridique plurielle (islamique, coutumière et civiliste), il a connu depuis sa création en 1955 plusieurs mutations profondes reflétant l'évolution du cadre constitutionnel et des priorités de l'État. La Constitution de 2011 constitue un tournant décisif : en consacrant l'indépendance du pouvoir judiciaire et en créant le Conseil Supérieur du Pouvoir Judiciaire (CSPJ), elle a redéfini le périmètre d'intervention du ministère, recentré désormais sur les missions administratives, financières et logistiques d'appui au système judiciaire (Ministère de l'Économie et des Finances, 2015).

Cette évolution s'est accompagnée d'une réforme progressive du système judiciaire, articulée autour de la Charte de la Réforme du Système Judiciaire adoptée en 2013, dont les axes ont été déclinés en programmes et actions budgétaires conformément à la Loi Organique relative à la Loi de Finances n° 130-13.

1.1.2 *Missions et attributions*

Les missions du ministère, telles que définies par le Décret n° 2.22.400 du 18 octobre 2022 relatif aux attributions et à l'organisation du ministère de la Justice, s'articulent autour de quatre domaines principaux :

- **La gestion administrative et financière des juridictions** : le ministère assure la gestion des ressources humaines, financières et logistiques des tribunaux de l'ensemble du territoire national. Il supervise l'organisation du travail administratif des greffes et assure la coordination entre les services judiciaires et les services déconcentrés.
- **La gestion du patrimoine et des infrastructures judiciaires** : construction, réhabilitation et équipement des palais de justice et des établissements pénitentiaires. Cette mission mobilise une part significative des crédits d'investissement du ministère.
- **La transformation numérique et la modernisation du service judiciaire** : pilotage de la transition numérique des juridictions, déploiement de plateformes

dématérialisées et intégration des technologies de l'information dans les procédures judiciaires et administratives.

- **La gestion des ressources humaines du personnel judiciaire et administratif** : recrutement, formation, avancement et gestion prévisionnelle des effectifs du corps des magistrats, des greffiers, des administrateurs et du personnel pénitentiaire.

Dans le cadre de la mise en œuvre de la Charte Nationale pour la Réforme du Système Judiciaire, le ministère poursuit l'édification d'une administration judiciaire professionnelle fondée sur la déconcentration administrative et financière. Le Projet de performance du PLF 2026 structure cette réforme autour de trois axes : la modernisation de la législation, la facilitation de l'accès à la justice et la qualification de l'administration judiciaire (Ministère de la Justice, 2025). Sur le plan numérique, la vision stratégique 2025–2030 vise à placer le justiciable au cœur de la transformation en déployant une justice numérique efficace et transparente et en mobilisant l'intelligence artificielle pour faciliter le travail de l'administration judiciaire, en partenariat avec le Programme des Nations Unies pour le développement (PNUD). Parmi les plateformes en cours de déploiement figurent la plateforme numérique du document adoulaire (dématérialisation des actes liés au mariage, au divorce et aux successions), la plateforme de traitement des demandes de certificat de nationalité marocaine pour les Marocains résidant à l'étranger, le portail de dépôt des demandes de grâce et de libération conditionnelle, ainsi que les plateformes d'échange de données avec les établissements bancaires et les compagnies d'assurance, encadrées par une convention tripartite avec l'ACAPS et la Fédération Marocaine des Assurances (FMA).

1.2 Organisation

Sur le plan organisationnel, le ministère de la Justice s'articule autour de deux composantes : les services centraux établis à Rabat et les services déconcentrés répartis sur l'ensemble du territoire national.

1.2.1 Services centraux

En vertu du Décret n° 2.22.400 du 18 octobre 2022, le ministère de la Justice est chargé de l'élaboration et de l'exécution de la politique du gouvernement dans le domaine de la justice, sans préjudice de l'indépendance du pouvoir judiciaire. L'organisation interne des divisions et services est précisée par l'Arrêté du Ministre de la Justice n° 1501.22 du 19 octobre 2022.

L'administration centrale regroupe, sous l'autorité du ministre, un Secrétariat Général, une Inspection Générale, huit directions thématiques et un institut de formation :

- La Direction des Affaires Civiles, des Professions Juridiques et Judiciaires

- La Direction des Affaires Criminelles, des Grâces et de la Surveillance de la Délinquance
- La Direction de la Législation et des Études
- La Direction de la Modernisation et des Systèmes d'Information
- La Direction des Ressources Humaines
- La Direction du Budget (*Modirriyat al-Mizâniyya*)
- La Direction de la Gestion des Équipements et du Patrimoine
- La Direction de la Coopération et de la Communication
- L'Institut National du Greffe et des Professions Juridiques et Judiciaires (INFCJ)




FIGURE 1 – Organigramme du ministère de la Justice (source : Décret n° 2.22.400).

Au sein du ministère, la Direction du Budget constitue l'interlocuteur principal avec le ministère de l'Économie et des Finances (MEF) et la Trésorerie Générale du Royaume (TGR). Son rôle est détaillé à la [section 1.3](#).

1.2.2 Services déconcentrés

Les services déconcentrés constituent la composante opérationnelle de l'institution. Ils comprennent notamment :

- La Cour de cassation (siège à Rabat), juridiction suprême de l'ordre judiciaire ordinaire
- Les Cours d'appel et les Cours administratives d'appel, réparties dans les grandes villes du Royaume

- Les Tribunaux de première instance (TPI) et les sections de justice de proximité
- Les Tribunaux administratifs et les Tribunaux de commerce
- Les établissements pénitentiaires gérés par la Direction Générale de l'Administration Pénitentiaire et de la Réinsertion (DGAPR)

L'ensemble du réseau judiciaire couvre les douze régions du Royaume, avec des implantations dans la quasi-totalité des provinces et préfectures. Cette présence territoriale étendue explique en grande partie la complexité logistique et budgétaire de l'institution : des ordonnateurs secondaires déconcentrés reçoivent délégation de crédits et exécutent localement le budget, ce qui multiplie les flux budgétaires à suivre et à anticiper.

1.3 La Direction du Budget

1.3.1 Composition et positionnement

Au sein de l'organigramme ministériel, la Direction du Budget joue un rôle central dans la gestion des ressources financières de l'institution. Rattachée hiérarchiquement au Secrétariat Général, elle constitue l'interface principale entre le ministère de la Justice d'une part, et le MEF et la TGR d'autre part.

Composition : Conformément à l'article 30 du décret organisant les structures du ministère (B.O. n° 7161), la Direction du Budget comprend les entités suivantes :

- **Division de la gestion du budget et de la comptabilité** (*qism tadbir al-mizâniyya wa-l-muhâsaba*) : gestion des engagements de dépenses et des paiements, suivi des comptes affectés à des fins spéciales, délégations de crédits aux ordonnateurs secondaires, et élaboration des situations annuelles d'exécution budgétaire.
- **Division des comptes des tribunaux** (*qism hisâbât al-mahâkim*) : suivi et centralisation des comptes des tribunaux, gestion des comptes assignés aux caisses des tribunaux, et suivi des paiements électroniques.
- **Division du recouvrement** (*qism al-tahşîl*) : suivi du recouvrement des amendes et condamnations pécuniaires, des frais et dépens judiciaires, et des paiements électroniques liés aux opérations de recouvrement.
- **Division de la prévision et de la programmation financière** (*qism al-tawaqqu' wa-l-barmaja al-mâliyya*) : élaboration des programmes budgétaires pluriannuels et du projet de budget annuel du ministère, préparation du projet de performance et du rapport de nageât al-adâ', conduite du dialogue de gestion avec les tribunaux, et prévision, suivi et évaluation de l'exécution budgétaire.
- **Service des affaires techniques et logistiques** (*maslahat al-shu'ûn al-tiqniyya wa-l-lujistikiiyya*) : appui technique et logistique aux divisions de la direction.

C'est la **Division de la prévision et de la programmation financière** qui constitue le terrain direct de notre recherche : elle produit les prévisions budgétaires annuelles et triennales et dispose de l'historique d'exécution nécessaire à la modélisation.




FIGURE 2 – Structure de la Direction du Budget du ministère de la Justice.

1.3.2 Fonctions et interfaces

Les fonctions de la Direction du Budget couvrent l'ensemble du cycle de vie budgétaire :

- **La programmation budgétaire** : coordination de l'élaboration des projets de performance annuels et triennaux (PBT-CDMT), consolidation des besoins remontés par les directions centrales et les services déconcentrés, et défense des demandes de crédits lors des conférences budgétaires avec la Direction du Budget du MEF.
- **L'exécution budgétaire** : gestion des crédits délégués, suivi des engagements, coordination avec les ordonnateurs secondaires déconcentrés, et suivi du taux de consommation des crédits en temps réel via le système GID de la TGR.
- **Le reporting et le contrôle de gestion** : production des tableaux de bord budgétaires périodiques, renseignement des indicateurs de performance contractualisés avec le MEF, et alimentation des Rapports Annuels de Performance (RAP) transmis au Parlement conformément à la LOF 130-13.
- **La gestion des archives d'exécution financière** : extraction, compilation et archivage des états d'exécution budgétaire mensuels produits par le système GID, qui constituent la matière première de notre analyse empirique (voir chapitre 3).
- **La gestion des restes à payer** : suivi des engagements pluriannuels non encore soldés, coordination avec la TGR pour les ordonnancements différés, et pilotage de la trésorerie budgétaire.

Interfaces externes : Dans l'exercice de ses missions, la Direction du Budget interagit avec plusieurs acteurs extérieurs au ministère. La **Direction du Budget du MEF** fixe les enveloppes dans les lettres de cadrage et arbitre les demandes lors des conférences budgétaires annuelles. La **TGR** assure l'exécution comptable et le contrôle des dépenses via le système de Gestion Intégrée de la Dépense (GID), déployé depuis 2009 pour offrir une vision en temps réel de l'état de consommation des crédits (El Moussali, 2023). L'**Inspection Générale des Finances (IGF)** procède à des audits périodiques de la

gestion financière. Le **Cour des Comptes** exerce le contrôle juridictionnel *a posteriori* sur les comptes publics, et ses observations alimentent annuellement le dialogue de gestion entre le ministère et le MEF.

C'est dans ce contexte que s'inscrit la problématique de ce mémoire. La Direction du Budget dispose d'un historique riche de données d'exécution budgétaire, mais les méthodes de prévision conventionnelles restent insuffisamment adaptées à la complexité des dynamiques de dépense. Ceci soulève la question centrale de notre recherche :

Dans quelle mesure les modèles de Machine Learning peuvent-ils améliorer la prévision du taux d'exécution budgétaire au sein du ministère de la Justice, et comment ces prévisions peuvent-elles alimenter un système d'aide à la décision pour un pilotage proactif des crédits en cours d'exercice ?

Cette question ne postule pas que le Machine Learning *surpasse* nécessairement les méthodes statistiques classiques sur un critère de précision brut : elle s'interroge sur la **valeur ajoutée opérationnelle** que ces outils peuvent apporter à un gestionnaire budgétaire (détection précoce des lignes à risque, generation de scénarios, aide à la réallocation des crédits) là où une simple moyenne historique ne fournit qu'une projection passive.

1.3.3 La Division de Prévision et de Programmation Financière

C'est au sein de cette direction, et plus précisément dans la **Division de Prévision et de Programmation Financière** (*qism al-tawaqqu' wa-l-barmaja al-mâliyya*), que s'est déroulé notre stage. Définie par l'article 34 du décret n° 2.22.400¹, cette division est investie des missions suivantes :

1. **Élaboration des programmes budgétaires pluriannuels et du projet de budget annexe annuel** du ministère : traduction des orientations stratégiques en enveloppes financières pluriannuelles (CDMT triennal) et construction du projet de budget préparé à l'occasion de chaque loi de finances.
2. **Préparation du projet et du rapport de performance** (*naja'at al-adâ'*) annexés au projet de loi de finances : formalisation des objectifs stratégiques, définition des indicateurs et renseignement des cibles, conformément aux exigences de la LOF 130-13.
3. **Préparation et conduite du dialogue de gestion avec les tribunaux** (*hiwâr al-tadbîr ma'a al-mahâkim*) : animation de la concertation annuelle avec les ordonnateurs secondaires déconcentrés pour la répartition des crédits et la négociation des objectifs de performance.

1. Bulletin Officiel n° 7161 du 16 janvier 2023, page 485.

4. **Élaboration des programmes contractuels et suivi de leur exécution** : mise en œuvre des engagements contractualisés avec le MEF, pilotage des programmes d'investissement pluriannuels et reporting périodique sur l'avancement physique et financier.
5. **Pilotage financier des projets et coordination avec les partenaires institutionnels** : gestion des partenariats, suivi des conventions de financement et articulation avec les bailleurs de fonds institutionnels.
6. **Prévision, suivi et évaluation de l'exécution budgétaire, et accompagnement des services déconcentrés** en matière financière et comptable : c'est la mission *cardinale* au regard de notre recherche. Elle implique la production de prévisions de taux d'exécution à horizon mensuel et trimestriel, le suivi des écarts entre crédits ouverts et crédits consommés, et le conseil proactif aux ordonnateurs secondaires sur les risques de sous-exécution ou de dépassement.
7. **Préparation du compte administratif et rapport sur l'exécution des dépenses budgétaires** : clôture annuelle du cycle budgétaire, consolidation des états comptables finals et production du bilan d'exécution transmis au MEF et à la Cour des Comptes.

C'est la mission 6 qui fonde directement l'utilité opérationnelle de ce mémoire : disposer de prévisions d'exécution fiables et précoces constitue, pour cette division, une exigence fonctionnelle permanente, que les méthodes actuelles fondées sur des extrapolations tendanciennes ou des comparaisons à l'année précédente ne satisfont qu'imparfaitement.

1.4 Enjeux et objectifs du mémoire

1.4.1 Enjeux du projet

Ce mémoire s'inscrit dans une démarche qui dépasse le simple exercice académique : il répond à des enjeux concrets et immédiats pour le ministère de la Justice et, plus largement, pour la gouvernance financière publique au Maroc.

- **Crédibilité budgétaire et redevabilité parlementaire** : La LOF 130-13 a institué l'obligation pour chaque ministère de produire un Rapport Annuel de Performance (RAP) présentant les réalisations par rapport aux prévisions. Des écarts persistants entre prévisions et exécution fragilisent la crédibilité de l'institution vis-à-vis du Parlement et de la Cour des Comptes ; ils signalent également un déficit de pilotage interne. Le Décret n° 2-22-580 du 3 mars 2023 rend désormais obligatoire, dans chaque département ministériel, un dispositif de contrôle de gestion destiné à « vérifier, en permanence, l'atteinte des objectifs de performance au regard des ressources allouées et à analyser les résultats par rapport aux prévisions » (Gouver-

nement du Maroc, 2023). Améliorer la qualité prédictive des prévisions est donc un enjeu de gouvernance autant que de gestion.

- **Optimisation de l'allocation des ressources** : Un ministère dont les crédits d'investissement sont systématiquement sous-consommés en début d'exercice et sur-sollicités en fin d'année subit un coût d'opportunité réel : des projets judiciaires (construction de tribunaux, équipement numérique) sont retardés, des restes à payer s'accumulent, et la qualité du service public se dégrade. Une meilleure anticipation des flux permet une allocation plus fluide et plus efficiente des crédits tout au long de l'année budgétaire.
- **Positionnement dans la transformation digitale de l'administration** : La Stratégie Nationale de Développement des Données Publiques et les orientations du Programme de Réforme de l'Administration placent la data et l'IA au cœur de la modernisation de l'État. Le ministère de la Justice, déjà engagé dans la transformation numérique de ses services aux justiciables, peut étendre cette démarche à son propre pilotage interne en expérimentant des modèles prédictifs sur ses données budgétaires.
- **Contribution à la recherche appliquée au contexte marocain** : La littérature sur l'application de l'IA à la prévision des dépenses publiques est abondante au niveau international mais quasi inexistante pour le contexte marocain à l'échelle ministérielle. Ce travail contribue à combler cette lacune et peut servir de référence méthodologique pour d'autres départements ministériels.

1.4.2 Objectifs de la recherche

Pour répondre à ces enjeux, ce mémoire poursuit trois objectifs articulés :

- **Constituer et analyser une base de données d'exécution budgétaire** : Collecter, nettoyer et structurer les rapports trimestriels d'exécution budgétaire publiés par la Trésorerie Générale du Royaume (TGR) sur la période 2020–2025 (24 observations), complétés par les morasses annuelles extraites du portail `lof.finances.gov.ma` ; analyser les propriétés statistiques des séries reconstituées (stationnarité, saisonnalité, effet COVID-19).
- **Développer et évaluer des modèles de prévision du taux d'exécution** : Construire, calibrer et évaluer plusieurs modèles, comprenant une régression linéaire régularisée (Lasso, puis Ridge après validation) et un algorithme de gradient boosting (XGBoost), ainsi que deux benchmarks naïfs (décalage annuel et moyenne historique), selon un protocole de validation *walk-forward* à fenêtre expansive ; mesurer leurs performances relatives via des métriques standardisées (RMSE, MAE, MAPE) ; analyser ce que ces résultats révèlent sur la structure des dépenses du ministère de la Justice.

- **Concevoir et implémenter un système d’aide à la décision opérationnel :**
Développer un tableau de bord interactif sous Power BI intégrant les prévisions T4 ligne par ligne et un module de détection d’anomalies fondé sur le score z du taux T2, illustrant comment les modèles prédictifs peuvent être mobilisés au service du pilotage budgétaire courant et formuler des recommandations concrètes pour leur appropriation par les équipes de la Direction du Budget.

1.4.3 Conclusion du chapitre

Ce premier chapitre a permis de poser le cadre institutionnel et organisationnel dans lequel s’inscrit notre recherche. À travers la présentation du ministère de la Justice (son histoire, ses missions, son organisation et la Direction du Budget qui en constitue le terrain direct), il est apparu que l’institution gère un budget complexe, territorialement déconcentré, soumis à des contraintes de performance croissantes depuis l’entrée en vigueur de la LOF 130-13.

La Division de la prévision et de la programmation financière produit des prévisions budgétaires annuelles à partir de méthodes qui restent, à ce jour, insuffisamment exploitées par les outils quantitatifs disponibles. C’est précisément cette lacune que ce mémoire se propose de combler, en explorant comment les apports du Machine Learning peuvent être intégrés dans le pilotage budgétaire : non pas comme un substitut aux méthodes existantes, mais comme un système d’aide à la décision capable de travailler à la granularité de la ligne budgétaire, de détecter les anomalies en cours d’exercice, et de quantifier le risque de sous-exécution en temps réel.

Le chapitre suivant approfondit le cadre budgétaire : composition du budget, dispositif LOF, cycle d’exécution et défis de la prévision. Cette analyse permettra d’identifier avec précision les séries et les variables sur lesquelles repose notre modélisation.

Chapitre 2 : La gestion budgétaire au Ministère de la Justice

Prévoir l'exécution budgétaire d'un ministère suppose d'en maîtriser le cadre. Ce chapitre décrit la structure du budget du Ministère de la Justice, les règles imposées par la LOF 130-13, et le cycle de la dépense publique. Il aboutit sur les difficultés concrètes de prévision qui motivent le recours à l'intelligence artificielle.

2.1 Le budget du Ministère

2.1.1 Composantes du budget

Conformément à l'article 12 de la LOF 130-13, le budget de tout ministère s'articule autour de trois instruments complémentaires (figure 3) :

- Le **budget général (BG)** : instrument principal retraçant l'ensemble des recettes et des dépenses de l'État, à l'exception de celles retracées dans les SEGMA et les CST. Il concentre la quasi-totalité des crédits du ministère de la Justice, répartis entre dépenses de fonctionnement (article 14) et dépenses d'investissement (article 17). C'est sur ce périmètre que porte l'analyse prédictive développée dans ce mémoire.
- Les **services de l'État gérés de manière autonome (SEGMA)** : services non dotés de la personnalité morale dont l'activité tend à produire des biens ou à rendre des services donnant lieu à rémunération (article 21). Leurs ressources propres doivent représenter au moins 30 % des ressources autorisées à compter de la troisième année suivant leur création, sous peine de suppression. L'insuffisance éventuelle est compensée par des subventions du budget général. Le ministère de la Justice dispose d'un SEGMA : le *Centre de Publication et de Documentation Judiciaire de la Cour de Cassation*.
- Les **comptes spéciaux du Trésor (CST)** : comptes retraçant des opérations spécialisées pour lesquelles un lien direct existe entre recette et dépense (article 25). Le ministère dispose de deux comptes d'affectation spéciale (CAS) :
 - Le *Fonds spécial pour le soutien des juridictions* : créé en 1993 sous le nom de « Fonds spécial pour l'extension et la rénovation des juridictions », il a connu plusieurs modifications (1998, 2004, 2011). Depuis 2011, il est alimenté par 56 % du produit des amendes et pénalités (hors code de la route), 56 % des recettes de la taxe judiciaire et 28 % des amendes routières, auxquels s'ajoutent des contributions du budget général. En 2014, ses crédits définitifs ont atteint 1,94 MMDH (Cour des Comptes, 2016).
 - Le *Fonds d'entraide familiale* : destiné au soutien des femmes divorcées dans le besoin.




FIGURE 3 – Composantes du budget du Ministère de la Justice.

2.1.2 Dépenses et recettes du budget général

Le budget général concentrant la quasi-totalité des crédits du ministère, c'est sur ce périmètre que porte l'analyse prédictive développée dans ce mémoire. Il met en regard deux grandes masses : les **dépenses**, qui couvrent les charges de fonctionnement et les dépenses d'investissement, et les **recettes**, qui correspondent aux ressources mobilisées par l'État (impôts et taxes, produit des amendes, rémunérations de services rendus, revenus du domaine de l'État et produit des emprunts) (LOF, article 11). Le budget du ministère se structure autour de deux grandes catégories de dépenses :

- Les **dépenses de fonctionnement** : composante dominante et largement rigide. Elles comprennent la masse salariale (magistrats, greffiers, personnel pénitentiaire, administrateurs) et les dépenses matérielles (alimentation des détenus, carburant, maintenance, fournitures). La masse salariale représente historiquement plus de 70 % des crédits de fonctionnement (Ministère de la Justice, 2023).
- Les **dépenses d'investissement** : consacrées à la construction et à la réhabilitation des palais de justice et des établissements pénitentiaires, ainsi qu'à l'équipement informatique et logistique. Au cours de la période 2010–2014, les crédits d'investissement inscrits au budget général ont atteint environ 3,26 MMDH (soit un montant annuel moyen de 651 MDH) (Cour des Comptes, 2016). Ces crédits présentent un profil d'exécution fortement concentré sur le dernier trimestre de l'exercice.

Sur le plan des recettes propres, le ministère génère des ressources liées à l'activité judiciaire : le produit des amendes et pénalités prononcées par les juridictions, les droits de

timbre judiciaires et la taxe judiciaire. La volatilité de ces ressources constitue un facteur d'incertitude supplémentaire dans la prévision globale.

2.2 Le cadre juridique de la gestion budgétaire

2.2.1 *Les apports de la réforme*

La loi organique n° 130-13 relative à la loi de finances, promulguée en juin 2015 et mise en œuvre progressivement entre 2016 et 2020, constitue le socle réformateur du cadre budgétaire contemporain. Conformément à son article premier, elle « détermine, pour chaque année budgétaire, la nature, le montant et l'affectation de l'ensemble des ressources et des charges de l'État, ainsi que l'équilibre budgétaire et financier qui en résulte » (Ministère de l'Économie et des Finances, 2015).

La LOF a opéré une rupture fondamentale avec l'ancienne logique de « budget de moyens » en instaurant une « budgétisation par la performance ». L'objectif est, selon la formule du Guide de construction des programmes budgétaires, de « faire mieux avec autant, voire moins de crédits que les années précédentes » (Direction du Budget, Ministère de l'Économie et des Finances, 2015). Cette nouvelle logique repose sur trois piliers :

- **La sincérité budgétaire** (article 10) : les prévisions doivent refléter fidèlement les informations disponibles, sous peine d'observations de la Cour des Comptes ou de critiques parlementaires.
- **La programmation triennale** (article 5) : chaque ministère élabore une programmation budgétaire couvrant l'année N et les deux années suivantes (N+1 et N+2), actualisée chaque année.
- **La gestion axée sur les résultats** : chaque programme est associé à des objectifs stratégiques et des indicateurs chiffrés, rendus publics dans les projets de performance (PdP) et les rapports annuels de performance (RAP) (Abdelali, 2019; Khallouk, 2019).

La LOF distingue trois catégories de loi de finances (article 2) : la **loi de finances de l'année**, qui prévoit et autorise l'ensemble des ressources et des charges pour un exercice donné ; la **loi de finances rectificative**, qui modifie en cours d'exercice les dispositions de la loi initiale ; et la **loi de règlement**, qui constate les résultats financiers de chaque année et approuve les écarts entre les prévisions et les réalisations. C'est précisément la réduction de ces écarts que les modèles prédictifs développés dans ce mémoire visent à faciliter.

2.2.2 La nomenclature budgétaire

La LOF a introduit une nouvelle architecture budgétaire organisée en sept niveaux hiérarchiques. Les six premiers niveaux sont présentés dans les morasses budgétaires ; le septième est réservé à l'exécution (Direction du Budget, Ministère de l'Économie et des Finances, 2015) :

1. **Les titres** (article 38) : Titre I (fonctionnement), Titre II (investissement), Titre III (dette publique).
2. **Les ministères ou institutions** : deuxième niveau de l'arborescence au sein de chaque titre.
3. **Les chapitres** : pour chaque ministère, un chapitre personnel et un chapitre matériel et dépenses diverses (fonctionnement), et un chapitre investissement.
4. **Les programmes** (article 39) : unité fondamentale de la budgétisation par la performance. Les crédits d'un programme sont répartis transversalement entre plusieurs chapitres.
5. **Les régions** (article 38) : niveau géographique permettant de suivre la répartition territoriale des crédits.
6. **Les projets ou actions** (articles 38 et 40) : déclinaison opérationnelle du programme en activités concrètes.
7. **Les lignes budgétaires** (article 41) : niveau d'exécution, renseignant la nature économique de la dépense. Ce niveau n'apparaît pas dans les morasses publiées avec le PLF ; il relève de la gestion interne du ministère et n'est rendu public que dans le projet de loi de règlement.

2.2.3 Les programmes budgétaires

Le programme constitue le niveau structurant de la réforme LOF. Conformément à l'article 39, « un programme est un ensemble cohérent de projets ou actions relevant d'un même département ministériel... auquel sont associés des objectifs définis en fonction des finalités d'intérêt général ainsi que des indicateurs chiffrés permettant de mesurer les résultats escomptés ».

Chaque programme se définit selon trois dimensions (Direction du Budget, Ministère de l'Économie et des Finances, 2015) :

- **Dimension budgétaire** : le programme correspond à une enveloppe de crédits consacrée à une politique publique. C'est à ce niveau que s'opère la *fongibilité asymétrique* : les gestionnaires peuvent redéployer des crédits à l'intérieur d'un même programme, à l'exception des crédits de personnel (Abdelali, 2019).

BUDGET DE FONCTIONNEMENT - PERSONNEL POUR L'ANNÉE BUDGETAIRE 2024

MINISTÈRE DE LA JUSTICE

Chapitre : 1.2.1.1.0.06.000

Code Fonc.	Prog.	Rég.	Proj.	NOMENCLATURES DES SERVICES ET DES DEPENSES	Crédits de Paiement pour l'année budgétaire 2024
				RUBRIQUES	
160	125	00	10	DROITS DE L'HOMME	
				SERVICES COMMUNS	
				Pilotage et gouvernance	13 269 000
				Total Région : 00	13 269 000
				Total Programme : 125	13 269 000
360	300	00	10	SOUTIEN ET PILOTAGE	
				SERVICES COMMUNS	
				Soutien des missions	3 179 307 000
				Total Région : 00	3 179 307 000
				Total Programme : 300	3 179 307 000
				TOTAL CHAPITRE : 1.2.1.1.0.06.000	3 192 576 000

FIGURE 4 – Extrait de la morasse budgétaire du Ministère de la Justice (exercice 2024).

- **Dimension managériale** : chaque programme est placé sous la responsabilité d'un responsable de programme, chargé de définir les objectifs, de piloter la mise en œuvre et de rendre compte des résultats. Cette responsabilité peut être portée par une personne ou par une équipe dédiée, et s'inscrit au sommet d'une pyramide de pilotage couvrant les niveaux central et déconcentré.
- **Dimension performance** : les objectifs et indicateurs du programme sont présentés dans le **Projet de Performance (PdP)**, transmis au Parlement en accompagnement du PLF. La reddition de comptes s'effectue à travers le **Rapport Annuel de Performance (RAP)**, publié avec le projet de loi de règlement.

Le ministère de la Justice dispose de quatre programmes budgétaires, dont la structure détaillée et l'évolution temporelle sont analysées au chapitre 3.

2.2.4 Le cycle de préparation du PLF

La préparation du Projet de Loi de Finances (PLF) suit un calendrier contraint fixé par la LOF (articles 47 et 48). Avant le 15 mars, le Chef du gouvernement invite par circulaire les ministères à établir leurs propositions de programmations budgétaires triennales assorties d'objectifs et d'indicateurs de performance. Avant le 15 avril, les ministères transmettent leurs propositions au MEF. Les commissions de programmation et de performance les examinent avant le 15 mai. En juillet, le ministre des finances présente les grandes lignes du PLF au Conseil du gouvernement. En septembre–octobre, les propositions sont centralisées et le PLF est déposé au Parlement au plus tard le 20 octobre. La Chambre des

représentants dispose de 30 jours pour se prononcer, suivis de 22 jours pour la Chambre des conseillers.




FIGURE 5 – Le cycle de préparation du Projet de Loi de Finances (PLF) au Maroc. *Note : le cycle débute en réalité dès mars par la circulaire du Chef du gouvernement aux ministères (LOF, art. 47) ; la phase Avril-Mai correspond à la soumission formelle des propositions au MEF.*

Ce calendrier contraint impose à la Direction du Budget de produire des prévisions fiables dans des délais courts : les propositions budgétaires doivent être finalisées dès le mois de mars pour une exécution qui ne débutera qu'en janvier de l'année suivante. C'est cette pression temporelle qui renforce l'intérêt d'outils automatisés et robustes de projection.

2.3 L'exécution budgétaire

2.3.1 Crédits d'engagement et crédits de paiement

L'article 18 de la LOF 130-13 organise le cycle d'exécution des dépenses d'investissement autour de deux instruments budgétaires distincts.

Le **crédit d'engagement (CE)** représente la limite supérieure des dépenses que les ordonnateurs sont autorisés à engager pour l'exécution des investissements prévus. L'engagement constitue le premier acte de la dépense : la décision par laquelle l'ordonnateur crée une obligation susceptible d'entraîner une charge pour l'État (signature d'un marché, commande de travaux). Les CE permettent des engagements pluriannuels tout en les rattachant à l'exercice de leur conclusion. Dans la pratique administrative, ce mécanisme est couramment désigné sous l'appellation « autorisation d'engagement » (AE), terminologie empruntée au droit budgétaire français mais non retenue dans la LOF marocaine.

Le **crédit de paiement (CP)** représente la limite supérieure des dépenses pouvant être ordonnancées et payées au cours d'un exercice pour honorer les engagements passés. Les CP constituent la traduction financière annuelle des CE, qui peuvent s'étaler sur plusieurs années pour des projets pluriannuels. La dissociation CE/CP génère des *restes à payer* (RAP), à savoir des CE engagés non encore couverts par des CP, dont la gestion constitue l'un des défis majeurs de la trésorerie de l'État (Abdelali, 2019).

2.3.2 Les quatre phases de la dépense

Le cycle complet de la dépense publique comprend quatre phases réglementaires, telles que définies par le Décret royal n° 330-66 portant Règlement Général de Comptabilité Publique (RGCP) (Gouvernement du Maroc, 1967). Ces phases s'organisent en deux volets distincts selon le principe fondamental de séparation des fonctions d'ordonnateur et de comptable public.

La phase administrative : du ressort de l'ordonnateur :

1. **L'engagement** : acte par lequel l'organisme public crée ou constate une obligation de nature à entraîner une charge. C'est la décision initiale qui prélève une partie des crédits budgétaires en faveur d'un créancier ;
2. **La liquidation** : vérification de la réalité de la dette et arrêt du montant exact de la dépense, au vu des pièces justificatives attestant le service fait ;
3. **L'ordonnancement** : acte administratif donnant l'ordre de payer la dette. La liquidation établit la dette ; l'ordonnancement lui confère un caractère exécutoire.

La phase comptable : du ressort du comptable public (TGR) :

4. **Le paiement** : acte par lequel l'organisme public se libère de sa dette. Le comptable public vérifie préalablement que le paiement est fait au véritable créancier, sur un crédit disponible et sur présentation de pièces régulières établissant la réalité du service fait.



FIGURE 6 – Le cycle des dépenses publiques : engagement, liquidation, ordonnancement et paiement.

Le cycle d'exécution au ministère de la Justice est caractérisé par une **saisonnalité marquée** : les dépenses de fonctionnement suivent un rythme relativement régulier, tandis que les dépenses d'investissement présentent un profil fortement concentré sur le dernier

trimestre, en raison des délais de passation des marchés publics et de la pression institutionnelle à consommer les crédits avant la clôture de l'exercice (Cour des Comptes, 2016).

2.3.3 Outils de suivi : GID et morasse

Le système GID : Le système de **Gestion Intégrée de la Dépense (GID)**, déployé par la TGR depuis 2009, constitue le référentiel central de l'exécution budgétaire dans l'ensemble des ministères marocains (El Moussali, 2023). Inspiré d'expériences internationales (CHORUS en France, SIGFE au Chili, GIRES au Canada), il couvre toutes les phases de la dépense publique (gestion des crédits, engagement, liquidation, ordonnancement et opérations de fin de gestion) et fournit une traçabilité complète de chaque opération depuis l'ouverture des crédits jusqu'au paiement par le comptable public.

La TGR met à disposition des ordonnateurs des **états d'exécution budgétaire** indiquant, pour chaque programme, action et ligne budgétaire, les montants des crédits ouverts, délégués, engagés, liquidés et ordonnancés. Ces états constituent la matière première de notre analyse empirique.

La morasse budgétaire : Il importe de distinguer ces états d'exécution de la **morasse budgétaire** au sens strict de la LOF. Cette dernière est un document annuel : l'annexe détaillée au Projet de Loi de Finances (PLF) qui présente, programme par programme et chapitre par chapitre, la structure des crédits demandés pour l'exercice à venir. Elle est publiée une fois par an lors du dépôt du PLF au Parlement. Notre analyse empirique s'appuie sur un jeu de données reconstitué à partir de deux sources complémentaires : la morasse budgétaire annuelle (structure des lignes, programmes, régions et projets) et les rapports d'exécution trimestriels publiés par la TGR (taux d'exécution agrégés). Ce jeu de données couvre la période 2020–2025 et est présenté en détail au chapitre 4.

Le portail e-Budget : Le portail **e-Budget** du MEF est utilisé en phase de programmation pour la saisie et la consolidation des propositions budgétaires lors des conférences annuelles. Malgré la disponibilité du GID et de e-Budget, une part significative du travail d'analyse demeure réalisée à l'aide de tableurs, générant des risques d'erreurs et des silos d'information que notre projet contribue à corriger.

2.4 La prévision budgétaire

2.4.1 Sources de complexité

La LOF exige des prévisions sincères, triennales et alignées sur des indicateurs de performance publics. Le Décret n° 2-22-580 du 3 mars 2023 renforce cette exigence en instituant dans chaque département ministériel un dispositif de contrôle de gestion chargé

de « mesurer les écarts entre les réalisations et les prévisions et d’analyser les causes et les conséquences des éventuels écarts » (article 7) (Gouvernement du Maroc, 2023). Or la pratique budgétaire au ministère de la Justice révèle des écarts persistants entre prévisions initiales et réalisations effectives. Plusieurs fragilités structurelles les expliquent (Abdelali, 2019) :

La saisonnalité des dépenses d’investissement : Les procédures de passation des marchés publics génèrent un cycle d’exécution concentré sur le dernier trimestre : les crédits liquidés en novembre-décembre représentent une proportion disproportionnée des réalisations annuelles. Un contrôle de la Cour des Comptes a révélé que le taux de paiement des programmes d’investissement variait entre 23 % et 32 % sur la période 2010–2014, tandis que les crédits reportés représentaient entre 42 % et 68 % des crédits ouverts (Cour des Comptes, 2016).

La rigidité de la masse salariale : Plus de 70 % des crédits de fonctionnement sont préengagés par des charges de personnel dont l’évolution dépend de décisions administratives (recrutements, avancements, promotions) difficiles à projeter finement sur plusieurs années.

La dissociation CE/CP et les restes à payer : Les engagements pluriannuels créent une dépendance entre exercices : les CP de l’année N sont en partie déterminés par les CE engagés en N-1 et N-2, ce que les méthodes classiques de prévision annuelle ignorent structurellement. Sur le Fonds spécial pour le soutien des juridictions, le taux d’engagement n’a oscillé qu’entre 28 % et 58 % des crédits de paiement au cours de la même période (Cour des Comptes, 2016).

La volatilité des dépenses opérationnelles : Les dépenses hors masse salariale (alimentation des détenus, carburant, maintenance) sont sensibles à des facteurs conjoncturels que l’extrapolation linéaire ne peut intégrer.

L’impact des chocs exogènes : La pandémie de COVID-19 (2020–2021) a illustré les limites des modèles fondés sur la continuité des tendances : suspension d’audiences, libérations exceptionnelles de détenus, gel de chantiers d’investissement.

2.4.2 Limites des méthodes actuelles

Les méthodes de prévision mobilisées actuellement au ministère s’appuient principalement sur l’extrapolation tendancielle et les projections linéaires. Ces approches présentent plusieurs limites face à la complexité des dynamiques budgétaires :

L’incapacité à capturer les **dynamiques non linéaires** : la concentration des dépenses d’investissement sur le dernier trimestre, l’accumulation des restes à payer, et les effets de seuil liés aux plafonds d’engagement ne peuvent être représentés par des fonctions

linéaires.

Le **manque de réactivité** : les méthodes tendanciennes intègrent lentement les nouvelles informations disponibles, alors que la préparation du PLF impose des actualisations fréquentes des prévisions entre mars et octobre.

La **fragmentation de l'information** : les données utiles sont dispersées entre plusieurs systèmes (GID, e-Budget, systèmes sectoriels de la DGAPR), et leur consolidation reste largement manuelle, coûteuse en temps et source d'erreurs.

L'absence de **mécanismes d'incertitude explicites** : les prévisions produites sont ponctuelles, sans intervalles de confiance permettant aux décideurs d'apprécier leur fiabilité relative.

2.4.3 Vers l'intelligence artificielle

Les insuffisances diagnostiquées dessinent un cahier des charges précis pour des outils de prévision alternatifs : capacité à capturer des dynamiques non linéaires et des saisonnalités marquées ; intégration de la dissociation CE/CP et des restes à payer ; réactivité face aux nouvelles informations ; et interprétabilité suffisante pour être défendable devant le MEF, le Parlement et la Cour des Comptes.

Les approches d'intelligence artificielle offrent des réponses adaptées à ces défis, à condition d'être sélectionnées en tenant compte des contraintes spécifiques du secteur public : un modèle qui prédit mieux mais ne peut pas être expliqué est inutile dans ce contexte. Quatre modèles seront évalués au chapitre 3, selon un double critère de précision et d'interprétabilité :

- Les **benchmarks naïfs** (moyenne historique et décalage annuel) : des références simples sans apprentissage statistique, qui fixent la barre minimale que tout modèle ML doit dépasser pour justifier sa complexité.
- La **régression linéaire régularisée** (Lasso, puis Ridge après validation) : modèle linéaire pénalisé, particulièrement adapté aux dépenses de matériel où les relations sont relativement stables et où la parcimonie favorise l'interprétabilité. La pénalité L_1 du Lasso a d'abord été retenue pour ses propriétés de sélection automatique de variables ; l'analyse post-validation a conduit à lui substituer une pénalité L_2 (Ridge), plus stable sur les configurations à faible effectif (cf. §4.5.5).
- **XGBoost** (gradient boosting par arbres) : capable de capturer des relations non linéaires et des effets de seuil, particulièrement performant sur les dépenses d'investissement à forte variabilité.

Les deux modèles ML sont évalués selon un protocole de validation walk-forward à fenêtre expansive, seul protocole garantissant qu'aucune information future ne contamine l'entraî-

nement. Le chapitre 3 développe les fondements théoriques de ces modèles et justifie les choix méthodologiques retenus.

Chapitre 3 : Fondements théoriques du Machine Learning appliqué à la prévision budgétaire

La prévision des taux d'exécution budgétaire est un problème difficile : les données sont peu nombreuses, les comportements varient d'une ligne à l'autre, et les méthodes statistiques classiques atteignent rapidement leurs limites. Ce chapitre présente les outils de Machine Learning retenus pour y répondre, en expliquant à chaque étape *pourquoi* ces outils ont été choisis, comment ils fonctionnent, et quelles précautions ont été prises pour garantir la fiabilité des résultats.

La première section expose les défis spécifiques de la prévision budgétaire. La deuxième section développe les fondamentaux de l'apprentissage supervisé et du compromis biais-variance. La troisième présente les quatre modèles retenus. La quatrième traite de la validation rigoureuse et de la prévention de la fuite de données.

3.1 Prévision budgétaire

3.1.1 Les défis spécifiques

Définition et principe : Le **Machine Learning** (ML) constitue une branche de l'intelligence artificielle qui dote les systèmes informatiques d'une capacité d'apprentissage automatique à partir des données, sans qu'une codification explicite des règles de décision par un expert ne soit nécessaire. Son principe directeur s'oppose à l'approche déterministe consistant à spécifier les règles a priori (par exemple : « *si le taux de réalisation en juin dépasse 40 %, alors la ligne sera satisfaisante en fin d'année* ») : l'algorithme se voit soumettre un ensemble d'exemples historiques dont l'issue est connue, à partir desquels il infert lui-même les régularités statistiques sous-jacentes.

Cette capacité est particulièrement précieuse pour la prévision budgétaire : les déterminants de l'exécution d'une ligne dépendent de facteurs nombreux et interdépendants (programme, région, rythme trimestriel, saisonnalité institutionnelle) qui seraient impossibles à encoder manuellement de façon exhaustive. En laissant le modèle découvrir ces relations depuis les données historiques, on obtient un outil adaptatif, capable de traiter simultanément des centaines de lignes budgétaires.

Les quatre familles du Machine Learning : Le ML ne se résume pas à un seul type d'apprentissage. Selon la nature des données disponibles et l'objectif poursuivi, on distingue quatre familles principales :

- **L'apprentissage supervisé :** le modèle apprend à partir d'exemples étiquetés, c'est-à-dire des paires (entrée, réponse connue). C'est la famille utilisée dans ce

travail pour prédire le taux d'exécution annuel à partir des taux trimestriels. Les algorithmes courants incluent la régression, les arbres de décision, les forêts aléatoires (Random Forest) et le gradient boosting (XGBoost).

- **L'apprentissage non supervisé** : aucune étiquette n'est disponible ; l'algorithme cherche des structures cachées dans les données (groupes similaires, réductions de dimensions). Le *clustering* est un exemple typique : il peut regrouper automatiquement les lignes budgétaires selon leur profil d'exécution, sans qu'on lui ait dit à l'avance combien de groupes existent.
- **L'apprentissage semi-supervisé** : une petite partie des données est étiquetée et une grande partie ne l'est pas. L'algorithme exploite les deux pour améliorer ses prédictions, ce qui est utile lorsque l'annotation manuelle est coûteuse.
- **L'apprentissage par renforcement** : un agent apprend en interagissant avec un environnement et en recevant des récompenses ou des pénalités selon ses décisions. Cette famille est surtout utilisée dans les jeux, la robotique et la gestion de systèmes dynamiques en temps réel.




FIGURE 7 – Les quatre familles du Machine Learning.

Dans notre contexte, l'apprentissage **supervisé** est le seul pertinent : nous disposons d'un historique d'exécutions passées (les étiquettes) et l'objectif est précis : prédire le taux annuel T_4 . Il est important de noter que le ML est une *branche* de l'intelligence artificielle : certains systèmes d'IA fonctionnent par règles écrites manuellement par un expert (on parle de *systèmes experts*) sans jamais apprendre à partir de données. Dans le contexte de la prévision budgétaire, où les dynamiques sont trop complexes pour être encodées à la main, c'est le ML supervisé qui s'impose naturellement.

Le cadre de l'apprentissage supervisé : Dans ce travail, nous utilisons exclusivement l'**apprentissage supervisé** : le modèle apprend à partir d'exemples pour lesquels la « bonne réponse » est connue. Chaque exemple est un couple :

- **Les variables d'entrée $\mathbf{x}_i$** (appelées *features*) : tout ce qu'on sait *avant* la fin de l'année (taux de réalisation au premier, deuxième et troisième trimestre, programme budgétaire, région, part de la ligne dans le budget total).
- **La variable à prédire y_i** (appelée *variable cible*) : le taux de réalisation annuel final T_4 , connu seulement en fin d'exercice.

Le modèle cherche une fonction f telle que $f(\mathbf{x}_i) \approx y_i$: étant donné ce qu'on sait en cours d'année, il estime ce que sera le taux final. En termes formels, l'algorithme minimise une **fonction de perte** $\mathcal{L}$, qui mesure l'écart entre la prédiction et la réalité, sur l'ensemble des exemples historiques :

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \sum_{i=1}^n \mathcal{L}(y_i, f(\mathbf{x}_i))$$

Dans notre application, $\mathcal{L}$ est l'erreur quadratique $(y - \hat{y})^2$, qui pénalise davantage les grandes erreurs de prédiction.

Comment se déroule un projet de Machine Learning ? Un projet de Machine Learning s'inscrit dans un cycle méthodologique structuré, allant de la collecte des données à leur intégration opérationnelle. Bien que présenté de manière séquentielle, il convient de souligner d'emblée qu'il s'agit d'un processus fondamentalement itératif, dans lequel les résultats de chaque phase informent en retour les décisions prises lors des phases antérieures. Dans le contexte du présent travail, ce cycle se décline selon les étapes suivantes :

1. **Collecte des données** : rassembler des données fiables et représentatives. Dans notre cas, il s'agit des rapports trimestriels d'exécution budgétaire publiés par la TGR sur la période 2020–2025, complétés par les morasses annuelles du ministère de la Justice.
2. **Préparation des données** : nettoyer, structurer et transformer les données brutes en un format exploitable par les algorithmes. Cette étape inclut la gestion des valeurs manquantes, la création des variables (features) et l'encodage des identifiants catégoriels (programme, région).
3. **Choix de l'algorithme** : sélectionner le type de modèle adapté au problème. Pour une prévision sur données tabulaires avec historique court, Ridge et XGBoost ont été retenus (voir section 3.3).
4. **Entraînement du modèle** : présenter les exemples historiques à l'algorithme. Celui-ci ajuste ses paramètres internes pour minimiser l'écart entre ses prédictions et les valeurs réelles, selon la formule ci-dessus.
5. **Évaluation** : tester le modèle sur des données qu'il n'a pas vues pendant l'entraînement, en mesurant son erreur via le RMSE, le MAE et le MAPE. Dans ce travail, cette évaluation se fait par validation walk-forward (section 3.4).
6. **Amélioration** : analyser les erreurs commises, ajuster les hyperparamètres (profondeur des arbres, taux de régularisation λ) et affiner l'ingénierie des features jusqu'à obtenir des performances satisfaisantes.

7. **Déploiement et surveillance** : intégrer le modèle dans un environnement opérationnel et surveiller en continu sa performance sur les nouvelles données, en le ré-entraînant si la structure des données évolue.

Ce cycle n'est pas linéaire : les résultats de l'évaluation conduisent souvent à revenir sur la préparation des données ou le choix des features. Dans notre travail, plusieurs itérations ont été nécessaires pour identifier et corriger les problèmes de fuite de données décrits en section 3.4.




FIGURE 8 – Cycle de fonctionnement d'un projet de Machine Learning : de la collecte des données au déploiement, avec itérations d'amélioration.

3.1.2 Pourquoi le Machine Learning

La prévision des taux d'exécution budgétaire présente trois caractéristiques qui rendent les approches classiques de séries temporelles difficiles à appliquer dans notre contexte : les comportements sont non linéaires, l'information pertinente est multidimensionnelle, et l'historique disponible par ligne est court. C'est précisément face à ces trois propriétés que le Machine Learning démontre le plus clairement sa valeur ajoutée.

Non-linéarités et effets de seuil : L'exécution budgétaire n'obéit pas à une logique de proportionnalité simple. Une ligne déjà à 60 % de réalisation au deuxième trimestre ne se comportera pas du tout de la même façon qu'une ligne à 10 %, même si l'écart brut avec leur historique respectif est identique. Il existe des **effets de seuil et d'accélération** : au-delà d'un certain niveau d'avancement, la dynamique d'exécution change de nature. Les algorithmes ML, en particulier les arbres de décision (XGBoost), détectent et modélisent ces ruptures automatiquement, sans qu'on ait besoin de les spécifier à l'avance.

Intégration des variables contextuelles : La capacité d'exécution d'une ligne budgétaire est tributaire d'une multiplicité de facteurs contextuels : la catégorie budgétaire (Investissement ou Fonctionnement selon la nature de la dépense), le programme de rattachement (Soutien et pilotage, Performance de l'administration judiciaire, Modernisation

du système judiciaire et juridique, ou Renforcement des droits et des libertés), la localisation régionale, la part relative de la ligne dans le budget global, ou encore les profils historiques de lignes comparables. Les algorithmes ML se distinguent précisément par leur capacité à intégrer simultanément l'ensemble de ces dimensions et à établir, de manière automatisée, le poids relatif de chacune d'entre elles selon le type de dépense et l'horizon de prévision considéré.

Mutualisation de l'information entre lignes budgétaires : Avec seulement 5 à 6 années d'historique par ligne, tout modèle traitant chaque ligne séparément travaille sur une base statistique fragile. Le ML résout ce problème en **agrégant toutes les lignes et toutes les années dans un seul jeu d'entraînement** : une ligne qui n'a que 5 années d'historique bénéficie des patterns observés sur l'ensemble du panel. Le modèle apprend des règles transversales : par exemple, que les lignes d'investissement en retard à mi-année rattrapent en général leur déficit au quatrième trimestre, ou que les lignes de fonctionnement à forte part budgétaire sont structurellement prévisibles. Cette mutualisation est l'un des avantages les plus décisifs de l'approche dans notre contexte.

Le tableau suivant synthétise ces propriétés :

TABLE 1 – Comparaison des méthodes classiques et des approches de Machine Learning.

Propriété	Méthodes classiques	ML (Ridge / XGBoost)
Non-linéarités et effets de seuil	Non	Oui
Variables contextuelles multiples	Limité	Naturellement intégrées
Courtes séries par ligne	Fragile	Robuste (mutualisation)
Interprétabilité	Coefficients	Coefficients (Ridge), importance (XGB)

3.1.3 Limites des approches classiques de prévision

Le chapitre 2 a recensé les principales méthodes de prévision utilisées dans la littérature budgétaire : modèles ARIMA/SARIMA, régressions saisonnières, lissages exponentiels. Ces approches reposent sur des hypothèses qui se révèlent difficiles à satisfaire dans notre contexte.

Premièrement, elles exigent des séries temporelles suffisamment longues par entité prédite : ARIMA recommande au moins 50 observations pour une estimation fiable, ce qui correspond à plus de 12 années de données trimestrielles par ligne. Avec seulement 5 à 6 ans d'historique, l'estimation des paramètres est instable et les intervalles de confiance très larges.

Deuxièmement, ces méthodes traitent chaque ligne budgétaire de façon isolée : elles ne peuvent pas exploiter le fait que des lignes relevant du même programme ou de la même ré-

gion partagent des dynamiques communes. L'information potentiellement précieuse contenue dans les centaines de lignes du budget n'est pas mutualisée.

Troisièmement, l'intégration de variables contextuelles explicatives (programme, région, indicateurs judiciaires) dans un modèle ARIMA requiert des extensions ARIMAX qui augmentent considérablement sa complexité sans garantir une amélioration sensible des performances quand l'historique est court. Ces limites motivent le recours au Machine Learning, dont les apports spécifiques à notre contexte ont été présentés en section 3.1.2.

3.2 Apprentissage supervisé

3.2.1 Généralisation

Un modèle ML n'a de valeur que s'il prédit correctement des situations qu'il n'a *jamais vues*. Or un algorithme suffisamment puissant peut « mémoriser » tous ses exemples d'entraînement sans réellement comprendre les patterns sous-jacents. Ce phénomène s'appelle le **surapprentissage** (*overfitting*) : le modèle performe brillamment sur ses données d'entraînement et échoue sur de nouvelles données. La **généralisation** désigne précisément la capacité d'un modèle à maintenir ses performances sur des données inédites, critère déterminant pour un usage opérationnel.

La généralisation dépend d'un équilibre délicat entre la complexité du modèle et la quantité de données disponibles. Un modèle trop simple ne captera pas les patterns importants ; un modèle trop complexe les mémorisera sans les comprendre. Cet équilibre est formalisé par le compromis biais-variance.

3.2.2 Le compromis biais-variance

L'erreur totale d'un modèle peut toujours se décomposer en trois termes :

$$\text{Erreur totale} = \underbrace{\text{Biais}^2}_{\text{modèle trop simple}} + \underbrace{\text{Variance}}_{\text{modèle trop complexe}} + \text{Bruit irréductible}$$

- Le **biais** traduit un *sous-apprentissage* : le modèle est trop simple et rate des patterns importants. Exemple : supposer que le taux final est toujours égal au taux du deuxième trimestre.
- La **variance** traduit un *surapprentissage* : le modèle est trop complexe et apprend le bruit au lieu du signal. Il s'adapte parfaitement à l'historique, mais généralise mal.
- Le **bruit irréductible** : une partie de la réalité est par nature imprévisible (décisions politiques de dernière minute, suspensions de dépenses imprévues, événements exceptionnels). Aucun modèle ne peut l'éliminer.

Les métriques d'évaluation quantifient cet écart entre prédictions et réalité. Trois indicateurs sont utilisés dans ce travail :

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad \text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad \text{MAPE} = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \%$$

- Le **RMSE** (Racine de l'Erreur Quadratique Moyenne) est la métrique principale. Il pénalise plus fortement les grandes erreurs : se tromper de 20 % est bien pire que deux erreurs de 10 %.
- Le **MAE** (Erreur Absolue Moyenne) donne l'erreur typique en valeur absolue, moins sensible aux cas exceptionnels.
- Le **MAPE** (Erreur Absolue Moyenne en Pourcentage) exprime l'erreur en pourcentage, ce qui facilite la comparaison entre lignes de niveaux très différents.

Dans notre protocole, le RMSE sert de critère principal de sélection des modèles ; MAE et MAPE sont présentés en complément dans les tableaux du chapitre 4.

3.2.3 Surapprentissage et robustesse

Avec seulement 5 à 6 années d'historique par ligne, un modèle très complexe risque fortement de mémoriser les données plutôt que d'en extraire des règles généralisables. Nous privilégions donc des modèles **régularisés** (Lasso et XGBoost avec pénalités L_1/L_2) qui incluent un mécanisme interne limitant leur propre complexité, trouvant ainsi le bon équilibre entre simplicité et précision.

Trois contraintes spécifiques à notre contexte plafonnent par ailleurs la précision atteignable :

1. **Volume de données limité** : cinq à six années d'historique par ligne représentent un volume modeste. Les modèles à grand nombre de paramètres risquent de mémoriser ces quelques exemples plutôt que d'en extraire des règles robustes.
2. **Données partiellement synthétiques** : les taux d'exécution publiés par la Trésorerie Générale du Royaume (TGR) sont des agrégats par catégorie, sans ventilation par programme ni par région. La construction du panel désagrégé repose donc sur une simulation calibrée (décrite au chapitre 4), ce qui introduit une imprécision structurelle dans les données d'entraînement.
3. **Variables non observables** : certains facteurs qui influencent l'exécution budgétaire ne figurent tout simplement pas dans les données : une décision de suspendre temporairement des dépenses en cours d'année, un retard dans le lancement d'un

appel d’offres, ou une réallocation de crédits d’un programme vers un autre décidée au niveau central. Ces événements, invisibles pour le modèle, peuvent pourtant modifier significativement le niveau de consommation observé en fin d’année. Même le meilleur algorithme ne peut pas prédire ce qu’il ne voit pas.

3.3 Les modèles retenus

Quatre modèles ont été évalués dans ce travail : deux **benchmarks naïfs** (sans apprentissage statistique) qui servent de barre minimale, et deux **algorithmes ML** à proprement parler. Le choix a été guidé par deux critères : la pertinence théorique face aux données budgétaires, et la faisabilité d’un déploiement réel dans une administration publique (un modèle trop opaque ou trop coûteux à maintenir n’a pas de valeur opérationnelle).

3.3.1 Modèles de référence (benchmarks naïfs)

Avant l’introduction de tout modèle sophistiqué, il convient d’établir des références méthodologiques simples : des prévisions qu’un gestionnaire pourrait produire sans recours à des techniques avancées, et qui constituent dès lors la borne minimale que tout modèle de Machine Learning se doit de surpasser pour justifier sa complexité additionnelle.

Benchmark 1 : Moyenne historique : Le benchmark le plus élémentaire repose sur l’extrapolation directe de la performance historique : si une ligne a réalisé en moyenne 82 % de son enveloppe annuelle au cours des cinq derniers exercices, on projette ce même taux d’exécution pour l’année en cours.

$$\hat{y}_i = \frac{1}{N} \sum_{t=1}^N y_{i,t}$$

où $\hat{y}_i$ est la prévision pour la ligne i , N le nombre d’années d’entraînement, et $y_{i,t}$ le taux d’exécution réel de la ligne i en année t .

Ce benchmark capture la **persistance structurelle** du taux d’exécution : certaines lignes sont structurellement bien exécutées, d’autres chroniquement sous-exécutées. Ignorer cet historique serait une erreur.

Benchmark 2 : Naïf saisonnier lag-4 : Une variante alternative consiste à projeter, pour l’année courante, le taux d’exécution exactement réalisé lors de l’exercice antérieur.

$$\hat{y}_i = y_{i,Y-1}$$

où $y_{i,Y-1}$ est le taux d’exécution réel de la ligne i l’année précédente.

Ce benchmark s'avère souvent difficile à surpasser en pratique, dans la mesure où il capture implicitement les phénomènes d'inertie institutionnelle et les tendances récentes de la dynamique budgétaire. Par conséquent, un modèle de Machine Learning incapable de produire des prévisions plus fiables que cette simple reconduction n'apporte aucune valeur ajoutée opérationnelle.

Ces deux benchmarks constituent la **barre minimale** que les modèles ML doivent franchir pour justifier leur déploiement.

3.3.2 Ridge (régularisation)

Principe en langage clair : La régression linéaire classique cherche la combinaison de variables qui prédit le mieux le taux final : « le taux final vaut approximativement a fois le taux T2, plus b fois la part budgétaire, plus une constante ». Le problème : avec beaucoup de variables et peu d'observations, le modèle peut attribuer des coefficients aberrants à des variables peu informatives, ce qui nuit à la généralisation.

Le **Ridge** (Tikhonov regularization) ajoute une contrainte : les coefficients trop grands sont pénalisés. Contrairement au Lasso qui force certains coefficients à zéro, Ridge réduit progressivement tous les coefficients vers zéro sans les éliminer complètement. Cela produit un modèle plus stable et robuste, particulièrement utile en présence de données avec outliers.

$$\min_{\beta_1, \dots, \beta_p} \underbrace{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}_{\text{erreur de prédiction}} + \lambda \underbrace{\sum_{j=1}^p \beta_j^2}_{\text{pénalité L2 sur les coefficients}}$$

Les β_j sont les coefficients du modèle. λ est choisi par validation croisée.

Le paramètre λ contrôle l'intensité de cette contrainte : plus λ est grand, plus les coefficients sont réduits. Sa valeur est choisie automatiquement par validation croisée (voir section 3.4).

Pourquoi Ridge pour les dépenses de matériel ? Les dépenses de matériel et dépenses diverses ont un profil d'exécution **régulier et prévisible**, avec peu de variation d'une année à l'autre. Dans ce contexte, l'hypothèse de linéarité est raisonnable. Ridge est particulièrement adapté car (1) il limite le surapprentissage sur peu de données, (2) il conserve tous les prédicteurs même faibles, ce qui améliore la stabilité face aux outliers, et (3) ses résultats restent interprétables : un gestionnaire peut comprendre qu'« une hausse d'un point de pourcentage du taux au deuxième trimestre se traduit par une hausse de β_{T2} points du taux annuel final ».

Note sur la normalisation : Les variables d'entrée doivent être normalisées avant d'être soumises à Ridge. Deux stratégies sont possibles : le *StandardScaler*, fondé sur la moyenne et l'écart-type (optimal pour distributions gaussiennes, sensible aux valeurs extrêmes), ou le *RobustScaler*, fondé sur la médiane et l'intervalle interquartile (plus robuste en présence d'outliers). Le choix dépend de la structure des données. Dans ce travail, le *RobustScaler* s'est révélé supérieur sur les dépenses de matériel car il neutralise les anomalies de courte durée (voir section 4.5.5 pour les détails d'optimisation post-validation).

3.3.3 Méthodes d'ensemble (XGBoost)

Principe en langage clair : Le **gradient boosting** repose sur un principe de correction itérative des erreurs mis en œuvre par un ensemble séquentiel de modèles faibles : un premier modèle produit une estimation initiale ; chaque modèle subséquent se concentre spécifiquement sur la correction des résidus engendrés par les précédents. Cette approche cumulative, par laquelle l'ensemble des corrections successives s'agrègent, conduit à une prévision globale sensiblement plus fidèle que celle qu'aurait pu fournir un modèle unique considéré isolément.

Dans XGBoost, chaque « expert » est un **arbre de décision** : une suite de questions simples du type « est-ce que le taux T2 est supérieur à 45 % ? » qui débouche sur une prévision. L'algorithme construit une séquence d'arbres $T_1, T_2, \dots, T_K$, chacun corrigeant les erreurs du précédent :

$$\underbrace{\hat{y}_i^{(k)}}_{\text{nouvelle prévision}} = \underbrace{\hat{y}_i^{(k-1)}}_{\text{prévision précédente}} + \eta \cdot \underbrace{T_k(x_i)}_{\text{correction de l'arbre } k}$$

où η est un « taux d'apprentissage » qui contrôle à quel point chaque correctif est appliqué (une valeur faible rend l'apprentissage plus prudent). La prévision finale est la somme de tous les arbres :

$$\hat{y}_i = \sum_{k=1}^K \eta \cdot T_k(x_i)$$

Pour éviter le surapprentissage, chaque arbre est contraint dans sa complexité par des paramètres de régularisation : limite sur la profondeur des arbres, pénalités sur les feuilles, et sous-échantillonnage aléatoire des données à chaque étape.

Pourquoi XGBoost pour les dépenses d'investissement ? Le choix de XGBoost pour les dépenses d'investissement se fonde sur une observation empirique déterminante : les dynamiques d'exécution de cette catégorie présentent des **non-linéarités pronon-**

cées. À titre d'illustration, une ligne dont le taux d'exécution s'établit à 5 % au deuxième trimestre, rattachée à un programme d'investissement en infrastructure, peut atteindre 80 % en clôture d'exercice grâce à des décaissements massifs concentrés en fin d'année — phénomène qu'un modèle linéaire ne saurait anticiper. XGBoost s'avère particulièrement adapté à ce type de configuration, et ce pour les raisons suivantes :

- Il capture naturellement les **effets de seuil et les interactions** : l'effet du taux T2 peut être différent selon le programme, la région ou la taille de la ligne.
- Il **généralise bien avec peu de données** : contrairement aux réseaux de neurones, XGBoost est efficace avec quelques centaines d'observations grâce à sa régularisation intégrée.
- Il est **interprétable** : l'importance de chaque variable (combien elle contribue en moyenne aux prédictions) peut être extraite et présentée à des gestionnaires non-spécialistes.
- Il est **open-source et rapide** : déployable sans licence commerciale, son exécution sur un ordinateur de bureau standard prend quelques secondes, un impératif dans un contexte ministériel.

3.3.4 Couche de détection d'anomalies

En complément des prévisions, le système intègre une **couche de détection d'anomalies de sous-exécution**. Le principe est simple : *le système calcule un score Z par ligne, comparant son taux d'exécution $T2$ à sa propre moyenne historique. Une déviation de plus de 1,5 écarts-types déclenche une alerte opérationnelle*. Formellement, pour chaque ligne budgétaire i , on calcule un **score Z** comme suit :

$$z_i = \frac{\text{taux}_{i,T2} - \mu_i}{\sigma_i}$$

où μ_i et σ_i sont la moyenne et l'écart-type du taux $T2$ de la ligne i sur les années d'entraînement.

Une ligne est **signalée comme anomalie** si $z_i < -1,5$, ce qui indique que son niveau d'exécution à mi-année est statistiquement anormal par rapport à son propre historique. Trois niveaux de sévérité sont distingués :

- **Exécution nulle** : taux $T2 = 0$, aucun décaissement enregistré ;
- **Sous-exécution sévère** : $z_i < -2$, écart très inhabituel ;
- **Sous-exécution modérée** : $-2 \leq z_i < -1,5$, signal d'alerte préventive.

Cette couche ne constitue *pas* une détection de fraude au sens pénal : elle identifie des **anomalies opérationnelles** – lignes bloquées administrativement, crédits non encore

délégués, ou projets n'ayant pas démarré – qui nécessitent une intervention de pilotage avant la clôture de l'exercice.

3.3.5 Justification des modèles écartés

Principe : Le Random Forest fonctionne lui aussi sur le principe d'une « équipe d'arbres », mais différemment : au lieu de travailler en séquence (chacun corrigeant le précédent), les arbres travaillent **en parallèle et indépendamment**, chacun entraîné sur un sous-ensemble aléatoire des données. La prévision finale est la moyenne de toutes leurs réponses :

$$\hat{y}_i = \frac{1}{B} \sum_{b=1}^B \underbrace{T_b(x_i)}_{\text{réponse de l'arbre } b}$$

B arbres votent indépendamment ; la prévision finale est leur moyenne.

Cette indépendance réduit le risque de surapprentissage, mais elle a un coût : les arbres ne se corrigent pas mutuellement, ce qui les rend moins précis individuellement.

Pourquoi Lasso a été écarté : Lasso (Least Absolute Shrinkage and Selection Operator) a initialement été considéré pour prédire les dépenses de matériel, car il offre une sélection automatique des prédicteurs. Cependant, la validation walk-forward a révélé ses limitations :

1. **Sensibilité aux outliers :** Le mécanisme de sélection (force certains coefficients à zéro) peut être fragilisé par quelques valeurs extrêmes, conduisant à des modèles instables d'une année à l'autre.
2. **Ridge plus stable :** Ridge (Régularisation L2) réduit progressivement tous les coefficients sans les éliminer, produisant une meilleure stabilité face aux outliers par normalisation avec RobustScaler.
3. **Performance empirique :** Sur les données du ministère de la Justice, Ridge + RobustScaler a surpassé Lasso + StandardScaler de 9,1 points de RMSE (voir section 4.5.5).

Lasso est néanmoins documenté dans les tableaux de comparaison du chapitre 4 comme algorithme initialement testé ; sa évaluation comparative appuie la pertinence du choix de Ridge pour ce contexte.

Pourquoi Random Forest a été écarté : Random Forest a été évalué lors de la validation walk-forward (détaillée au chapitre 4), mais n'a pas été retenu comme modèle de production, pour trois raisons :

1. **Performances inférieures** : XGBoost a systématiquement produit des erreurs plus faibles sur les dépenses d'investissement, la catégorie la plus complexe. L'entraînement sur des sous-échantillons aléatoires peut éliminer des patterns utiles quand les données sont rares.
2. **Incapacité à extrapoler** : les arbres de décision ne peuvent pas prédire au-delà des valeurs observées pendant l'entraînement. Pour des lignes dont les taux 2025 dépassent tous les niveaux historiques, Random Forest plafonne mécaniquement, tandis que XGBoost peut s'ajuster prudemment.
3. **Parcimonie opérationnelle** : dans un contexte de déploiement réel, retenir le modèle le plus performant par catégorie est préférable à empiler plusieurs algorithmes dans un ensemble hybride difficile à expliquer et à maintenir.

Random Forest est néanmoins présenté dans les tableaux de résultats du chapitre 4 comme point de comparaison ; sa mise en concurrence avec les autres modèles est un élément de rigueur méthodologique essentiel.

3.4 La validation rigoureuse

Construire un modèle ML n'est que la moitié du travail. L'autre moitié consiste à **mesurer honnêtement sa performance** : combien d'erreur fait-il sur des données qu'il n'a jamais vues ? Cette question semble simple, mais elle cache un piège redoutable dans le contexte des séries temporelles.

3.4.1 Les données temporelles

La validation croisée standard : efficace mais inadaptée ici : La validation croisée en k groupes (k -fold) constitue la méthode standard d'évaluation des modèles de Machine Learning : l'ensemble des données est partitionné en k sous-ensembles disjoints ; à chaque itération, l'un de ces sous-ensembles est réservé au test, tandis que le modèle est entraîné sur les $k - 1$ sous-ensembles restants. La performance globale est alors estimée par la moyenne des erreurs sur l'ensemble des folds.

TABLE 2 – Schéma de la validation croisée k -fold (exemple : Groupe 2 = test).

Groupe 1	Groupe 2	Groupe 3	Groupe 4	Groupe 5
Entr.	Test	Entr.	Entr.	Entr.

Groupe 2 = test ; groupes 1, 3, 4, 5 = entraînement

Si cette approche demeure valide lorsque les observations satisfont l'hypothèse d'indépendance mutuelle, son application à des données temporelles introduit un biais méthodologique critique : la permutation aléatoire des années au sein des groupes de validation autorise le modèle à accéder, lors de son entraînement, à des informations postérieures à la

période qu’il est censé prédire. Autrement dit, un modèle ayant « observé » les réalisations de 2024 pour prédire celles de 2022 bénéficie d’une divulgation implicite d’information temporelle, ce qui invalide dès lors la mesure de sa capacité prédictive réelle.

La contrainte fondamentale : toujours prédire vers l’avant : Pour les séries temporelles, une règle doit être respectée absolument : les données d’entraînement doivent toujours être antérieures aux données de test. Cela donne naissance à des protocoles de validation spécifiques.

3.4.2 Validation walk-forward

Le protocole retenu dans ce travail est la **validation walk-forward à fenêtre expansive**, qui reproduit fidèlement le cadre opérationnel auquel se trouvera confronté le décideur en conditions réelles. Concrètement :

- Pour prédire l’année 2022, le modèle s’entraîne uniquement sur 2020–2021.
- Pour prédire 2023, il s’entraîne sur 2020–2022.
- Pour prédire 2024, il s’entraîne sur 2020–2023.
- Pour prédire 2025, il s’entraîne sur 2020–2024.

La caractéristique centrale de cette approche réside dans l’élargissement progressif de la fenêtre d’entraînement à chaque étape temporelle, reflétant l’accumulation naturelle d’expérience historique au fil du temps. Ainsi, plus l’horizon de prévision se rapproche du présent, plus le modèle bénéficie d’un volume substantiel de données antérieures. La performance globale est in fine estimée en moyennant les erreurs commises sur les quatre périodes de test ainsi définies.

TABLE 3 – Protocole de validation walk-forward à fenêtre expansive (2022–2025).

	2021	2022	2023	2024	2025
Fold 1 (test 2022)	Entr.	Test			
Fold 2 (test 2023)	Entr.	Entr.	Test		
Fold 3 (test 2024)	Entr.	Entr.	Entr.	Test	
Fold 4 (test 2025)	Entr.	Entr.	Entr.	Entr.	Test
Entraînement	Test	Cases vides = données non encore disponibles			

Ce protocole présente trois avantages majeurs :

- **Simulation exacte du déploiement réel** : chaque fold reproduit fidèlement la situation du gestionnaire : il dispose de tout l’historique passé et prédit l’année courante.
- **Aucune contamination temporelle** : à aucun moment le modèle n’est entraîné sur des données postérieures à l’année qu’il prédit.

- **Mesure de la progression** : comparer les erreurs du fold 2022 (peu de données) à celles du fold 2025 (plus de données) quantifie l’apport de chaque année d’historique supplémentaire.

3.4.3 Risque de data leakage

Qu’est-ce que la fuite de données ? La **fuite de données** (*data leakage*) est une erreur qui consiste à laisser entrer dans le processus d’entraînement des informations qui ne seraient pas disponibles au moment d’une vraie prévision. Le modèle apprend alors des patterns « trop faciles » qui disparaissent en production. Le symptôme est trompeur : les métriques de validation semblent excellentes, mais le modèle déçoit une fois déployé.

Mécanisme 1 : fuite par le protocole de validation : Si le jeu de test est l’année 2022 mais que le modèle s’entraîne sur des données incluant 2023, 2024 et 2025, il « voit l’avenir » pendant l’entraînement. La méthode LOYO (*Leave-One-Year-Out*) commet exactement cette erreur : pour tester 2022, elle entraîne sur toutes les autres années y compris les années ultérieures, ce qui produit des métriques artificiellement optimistes. Le walk-forward élimine ce risque par construction.

Mécanisme 2 : fuite par les variables explicatives : Même avec un bon protocole, la fuite peut s’introduire lors de la construction des variables. Exemple typique : si on calcule « la moyenne historique des taux T3 de cette ligne sur toutes les années disponibles » et qu’on l’utilise pour prédire 2022, cette moyenne inclut les années 2023, 2024, 2025, soit des données futures. La solution est de calculer cette moyenne de façon **causale** : pour prédire l’année Y , n’utiliser que les années strictement antérieures à Y .

3.4.4 Prévision directe vs roulante

Motivation pratique : La validation walk-forward présentée en section 3.4.2 garantit une séparation temporelle stricte : le modèle ne voit jamais d’information future. Cependant, cette approche reflète un scénario académique où l’on prédisait à $t = 0$ l’intégralité d’une année budgétaire sans aucune donnée intra-annuelle.

En réalité, les gestionnaires budgétaires ne prédisent pas deux ans à l’avance : ils ont besoin de réviser les prévisions en cours d’exécution. Par exemple, à la mi-année (T2 écoulé), on dispose déjà des taux d’exécution réels pour T1 et T2, et l’enjeu est de prédire le taux final T4. Cette situation est fondamentalement différente, car elle combine :

1. Une **fenêtre d’observation** : données passées réelles (T1, T2)
2. Une **fenêtre de prédiction** : données futures inconnues (T4)
3. Une **fenêtre intermédiaire** : T3, potentiellement prédite ou observée

Deux stratégies de prédiction : **Approche directe :** Le modèle reçoit directement $T1$ et $T2$ observés comme entrées et produit en un seul passage la prédiction de $T4$ finale. Cette approche suppose que la relation $(T1, T2) \rightarrow T4$ peut être apprise directement depuis les données historiques, sans étape intermédiaire.

Approche roulante : Le processus de prédiction se décompose en deux étapes séquentielles :

1. **Étape 1 :** Prédire $T3$ à partir de $T1$ et $T2$ observés
2. **Étape 2 :** Prédire $T4$ à partir de $T1$, $T2$ observés *et* $T3$ prédit

L’approche roulante capture une structure temporelle progressive : on suppose que $T3$ est informatif pour prédire $T4$, et que les modèles bénéficient de cette information intermédiaire, même si elle est elle-même entachée d’erreur de prédiction.

Implications méthodologiques : Cette distinction revêt une importance capitale pour la conception du système de prévision. Alors que la validation walk-forward teste la capacité du modèle à généraliser dans le temps, la comparaison directe vs roulante interroge la **structure causale** de la prédiction : faut-il modéliser la dépendance $(T1, T2) \rightarrow T4$ de façon monolithique, ou la décomposer en étapes qui reflètent le déroulement temporel réel du trimestre ?

Les deux stratégies restent dans le cadre de la validation walk-forward : aucune information de $T4$ (année de test) ne fuit dans l’entraînement. Cependant, elles interrogent comment *structurer* la prédiction lorsqu’on dispose d’information partielle en cours d’année. Cette question présente un caractère à la fois théorique (quelle est la meilleure approche conceptuellement ?) et pratique (laquelle produit des prévisions plus fiables en situation opérationnelle ?). Les résultats empiriques figurent au chapitre 4.

3.4.5 Évaluation des modèles

Le taux de réalisation au troisième trimestre ($T3$, disponible fin septembre) est un prédicteur très puissant du taux annuel final. Mais si le modèle est utilisé *en juin* (après $T2$), inclure $T3$ constituerait une fuite : cette information n’existe pas encore. Notre implémentation propose donc deux prévisions distinctes :

- une **prévision du $T4$ basée sur $T2$** , disponible en juin (sans $T3$) ;
- une **prévision du $T4$ basée sur $T3$** , disponible en octobre (avec $T3$).

Cette distinction illustre que la maîtrise de la fuite de données est avant tout une condition de **confiance opérationnelle** : un modèle qui triche en entraînement produira des alertes erronées en production. Les détails d’implémentation sont présentés au chapitre 4.

3.5 Synthèse du chapitre

Ce chapitre a établi les fondements sur lesquels repose la démarche empirique du mémoire. Le Machine Learning a été justifié face aux approches classiques par sa capacité à mutualiser l'information entre lignes, à capturer des non-linéarités, et à fonctionner avec peu d'historique individuel. Parmi les quatre modèles évalués, Ridge et XGBoost ont été retenus pour leurs performances et leur adéquation au contexte opérationnel ; Lasso et Random Forest ont été évalués mais écartés. Enfin, la validation walk-forward (section 3.4.2) a été présentée comme le seul protocole qui simule fidèlement les conditions de déploiement réel, en éliminant par construction tout risque de fuite temporelle. Une variante pratique a également été proposée (section 3.4.4) : la prévision *directe* vs *roulante*, qui capture deux stratégies de prédiction selon que le gestionnaire dispose déjà de l'observation de T3 ou non.

Le chapitre suivant décrit la mise en œuvre empirique de ces principes : construction des données, implémentation des folds walk-forward, et résultats comparatifs obtenus sur le périmètre du ministère de la Justice pour la période 2022–2025.

Chapitre 4 : Construction du modèle prédictif et détection d'anomalies

Ce chapitre expose la mise en œuvre opérationnelle de la démarche prédictive conceptualisée dans le chapitre précédent. Après présentation du jeu de données et justification des variables retenues, nous procédons à une comparaison rigoureuse de plusieurs candidats algorithmiques, explicitons les métriques mobilisées pour leur évaluation, puis détaillons l'architecture finalement retenue ainsi que les prévisions produites pour l'exercice 2025. Une section dédiée traite ensuite de la détection statistique d'anomalies appliquée à ces prévisions. Le chapitre s'achève par une synthèse critique intégrant une discussion structurée des limites méthodologiques et empiriques du travail.

Vue d'ensemble : du traitement des données à la prévision

Ce travail repose sur un enchaînement rigoureux de phases interdépendantes. Chaque étape transforme les sorties de la phase antérieure en entrées pour la phase suivante. Le schéma suivant illustre cette progression :

ÉTAPE 1 : Assemblage des données (Section 4.1)

Source TGR (taux agrégés) + Morasses (nomenclature ligne par ligne)

⇒ Jeu de données désagrégé : 130 lignes, 6 ans, 4 trimestres ⇒ 3 120 observations au total

ÉTAPE 2 : Construction des variables (Section 4.2)

Jeu de données brut ⇒ Sélection et encodage des features

Variables explicatives : T1, T2, T3 (lag), budget, programme, région, ...

Variable cible : Taux T4 (ce qu'on veut prédire)

ÉTAPE 3 : Test de quatre modèles (Section 4.3 – 4.4)

Données préparées ⇒ Validation walk-forward sur 4 folds

Benchmark 1 : Moyenne historique

Benchmark 2 : Décalage annuel

Modèle 1 : Ridge (Linéaire régularisé)

Modèle 2 : XGBoost (Gradient boosting)

Résultat : RMSE, MAE, MAPE pour chacun

ÉTAPE 4 : Sélection spécialisée par catégorie (Section 4.5.1 – 4.5.2)

Résultats par catégorie (Investissement / Matériel / Personnel)

⇒ Investissement : XGBoost (meilleur)

⇒ Matériel : Ridge (meilleur)

⇒ Personnel : Moyenne historique (suffisant)

ÉTAPE 5 : Optimisation du modèle Matériel (Section 4.5.5 – 4.5.6)

Analyse post-validation des outliers et instabilités

Changements : StandardScaler → RobustScaler | Feature engineering & tuning

Feature engineering : Ajout de line_volatility

Gain : -9.1% RMSE, -35.2% sur cas extrêmes

ÉTAPE 6 : Prévisions T4 2025 (Section 4.5.4)

Modèles ré-entraînés sur 2021–2024 complets

Application aux 130 lignes 2025

Résultat : Prévisions + intervalles de confiance implicites (via RMSE)

ÉTAPE 7 : Détection d'anomalies (Section 4.6)

Prévisions T4 2025 + Taux T2 observés 2025

Calcul du z-score T2 par ligne (historique vs actuel)

Résultat : 4 anomalies identifiées (3 modérées, 1 sévère)

Les sections qui suivent développent chacune de ces étapes dans l'ordre. Le lecteur verra exactement comment les données brutes se transforment en prévisions opérationnelles, et comment chaque décision méthodologique influence les résultats finaux.

4.1 Présentation et construction des données

[PROCESSUS : ÉTAPE 1 – Assemblage des données]

Nous commençons par décrire les sources de données brutes et la manière dont elles ont été combinées pour créer un jeu de données désagrégué au niveau de la ligne budgétaire. C’est la fondation sur laquelle reposera tout modèle ultérieur.

Cette section décrit l’origine du jeu de données, la démarche suivie pour reconstituer les taux d’exécution au niveau de la ligne budgétaire à partir des sources publiques disponibles, et les principales caractéristiques statistiques de l’échantillon obtenu.

4.1.1 Source et périmètre des données

La constitution du jeu de données repose sur l’articulation de deux sources publiques complémentaires. En premier lieu, les **morasses budgétaires annuelles** publiées en annexe des projets de loi de finances (2020–2025) fournissent la nomenclature exhaustive des lignes budgétaires relevant du Ministère de la Justice ainsi que les enveloppes de crédits initialement allouées par ligne. En second lieu, les **rapports trimestriels d’exécution** émis par la Trésorerie Générale du Royaume (TGR) documentent les taux d’exécution agrégés, ventilés par catégorie de dépense.

Le tableau 4 résume la volumétrie du jeu de données final.

TABLE 4 – Volumétrie du jeu de données.

Dimension	Valeur
Période couverte	2020–2025 (6 exercices)
Nombre de lignes budgétaires distinctes	130
Nombre de programmes	4 (P300–P303)
Nombre de régions	13
Catégories de dépense	3 (Investissement, Matériel, Personnel)
Trimestres par ligne et par année	4 (T1–T4)
Nombre total d’observations	3 120

4.1.2 Construction du jeu de données

La TGR publie les taux d’exécution agrégés par catégorie de dépense, mais pas par ligne budgétaire individuelle. La morasse, de son côté, fournit la liste exhaustive des lignes et leur crédit initial. L’objectif a été de **combinaison ces deux sources** pour reconstituer un jeu de données aussi proche que possible de la réalité ministerielle. La procédure tient en trois idées simples :

1. **On part des chiffres réels** : les taux trimestriels par catégorie publiés par la TGR (2020–2025) constituent l’ancrage quantitatif du jeu de données. Aucune valeur n’est inventée : ces taux sont des chiffres officiels.
2. **On répartit ces taux sur les vraies lignes budgétaires** : la nomenclature programme → projet → région → ligne est extraite directement des morasses. Chaque ligne reçoit un profil d’exécution cohérent avec sa nature (les travaux exécutent tard, les fournitures régulièrement, le personnel linéairement).
3. **On vérifie que tout colle** : après répartition, la moyenne pondérée des taux par ligne reproduit exactement les agrégats TGR. Si ce n’est pas le cas, les valeurs sont recalées proportionnellement. Cette contrainte garantit qu’aucune statistique officielle n’est trahie.

Le résultat est un jeu de données **réaliste par construction** : les agrégats sont réels, la structure analytique est réelle, seule la distribution fine entre lignes d’un même programme est reconstituée selon des hypothèses opérationnelles plausibles.

4.1.3 Statistiques descriptives

La caractérisation empirique des dynamiques d’exécution constitue un préalable indispensable à la présentation des modèles algorithmiques. Trois observations structurantes émergent de cette analyse descriptive et orientent l’ensemble des développements ultérieurs.

Premier constat : une saisonnalité fortement marquée. Le tableau 5 montre la progression typique des taux du T1 au T4, toutes catégories confondues.

TABLE 5 – Statistiques du taux d’exécution par trimestre (toutes catégories, 2020–2025).

Trimestre	Moyenne	Écart-type	Min	Max
T1	6,7 %	11,3 %	0,0 %	49,0 %
T2	24,5 %	19,4 %	1,2 %	91,5 %
T3	49,6 %	24,1 %	8,6 %	119,3 %
T4	90,6 %	16,0 %	49,1 %	142,0 %

En moyenne, 25 % seulement de l’enveloppe budgétaire sont consommés à mi-parcours (T2), contre 91 % en clôture d’exercice (T4). C’est précisément cet écart substantiel qui confère à la prévision T4 son caractère non trivial et justifie sa pertinence opérationnelle : au 30 juin, l’essentiel du profil d’exécution reste à déterminer.

Deuxième constat : les trois catégories présentent des profils comportementaux radicalement divergents. Le tableau 6 détaille les statistiques du taux T4 par catégorie de dépense.

TABLE 6 – Statistiques du taux d'exécution T4 par catégorie budgétaire.

Catégorie	Nb obs.	Moyenne T4	Écart-type	Min	Max
Investissement	630	88,2 %	15,8 %	49,1 %	135,6 %
Matériel	144	100,5 %	13,0 %	76,0 %	142,0 %
Personnel	6	99,5 %	1,5 %	97,0 %	101,5 %

Le **Personnel** affiche une variance quasi nulle ($\sigma = 1,5$ points) : ces dépenses sont mécaniques et parfaitement prévisibles. Le **Matériel** présente une variabilité modérée. L'**Investissement**, en revanche, montre la plus forte dispersion ($\sigma = 15,8$ points) et des valeurs extrêmes allant de 49 % à 136 % : c'est la catégorie la plus difficile à anticiper, et celle pour laquelle un modèle prédictif apporte le plus de valeur.

Troisième constat : l'Investissement concentre les enjeux. Les figures 9 à 11 visualisent les profils saisonniers par catégorie. L'investissement exécute moins de 10 % en T1–T2 puis 70 % en T4 ; c'est ce comportement tardif qui justifie l'existence même d'un système d'alerte précoce.




FIGURE 9 – Profil saisonnier du taux d'exécution — Dépenses d'Investissement (2020–2025).




FIGURE 10 – Profil saisonnier du taux d'exécution — Dépenses de Matériel (2020–2025).




FIGURE 11 – Profil saisonnier du taux d'exécution — Dépenses de Personnel (2020–2025).

Ces trois constats motivent directement les choix méthodologiques qui suivent : des modèles distincts par catégorie (4.5), des variables explicatives privilégiant l'historique récent (4.2), et une méthode de détection d'anomalies ciblée sur les sous-exécutions atypiques au T2 (4.6).

4.2 Variables utilisées pour la prédiction

[PROCESSUS : ÉTAPE 2 – Construction et sélection des variables]

Une fois le jeu de données assemblé, l'étape suivante consiste à transformer les données brutes en variables explicatives interprétables et informatives. Cette section présente la variable cible (ce qu'on veut prédire), les variables explicatives (ce qu'on observe), et l'encodage des variables catégorielles.

4.2.1 Variable cible (taux T4)

La variable cible est le **taux d'exécution annuel d'une ligne budgétaire**, mesuré en fin d'exercice (au 31 décembre) :

$$\text{taux T4} = \frac{\text{crédits effectivement exécutés au cours de l'année}}{\text{crédits inscrits en loi de finances}}$$

Une valeur de 1,00 signifie que la ligne a consommé exactement son enveloppe annuelle ; 0,80 indique une sous-exécution de 20 points ; les valeurs supérieures à 1 correspondent à des dépassements (rares, possibles en matière de Matériel et de Personnel via les crédits supplémentaires). Le seuil métier de 80 % retenu par les équipes de la Division de la Prévision et de la Programmation financière (DPPF, rattachée à la Direction du Budget) sert de frontière entre une exécution acceptable et une exécution à risque.

4.2.2 Variables explicatives et justification du choix

La sélection des variables explicatives s'est appuyée sur trois critères d'admissibilité cumulatifs : (i) leur **disponibilité opérationnelle au 30 juin**, date calendaire fixant l'horizon de prévision ; (ii) leur **caractère informatif** quant aux déterminants de la dynamique d'exécution ; (iii) leur **interprétabilité** par les utilisateurs métiers, condition essentielle à l'adoption opérationnelle du système. Le tableau 7 récapitule l'ensemble des variables satisfaisant ces critères.

TABLE 7 – Variables retenues pour la prévision du taux d'exécution T4.

Variable	Ce qu'elle mesure	Dispo. 30 juin
<code>taux_T2</code>	Taux d'exécution observé à mi-parcours (fin juin de l'année en cours). Une valeur faible signale un retard déjà engagé.	Oui
<code>taux_T1</code>	Taux observé à fin mars ; capture le démarrage de l'exercice.	Oui
<code>taux_T4_lag</code>	Taux T4 de l'an passé : signal le plus fort du comportement habituel de la ligne.	Oui
<code>taux_T2_lag</code>	Taux T2 de l'an passé : permet de comparer le rythme actuel à celui de l'an précédent.	Oui
<code>hist_avg_T3</code>	Moyenne historique du taux T3 sur les années précédentes : capture si une ligne « rattrape » historiquement entre T2 et T3.	Oui
<code>lf_ratio, lf_share</code>	Dotation relative de la ligne et part dans son programme : détectent les dotations atypiques.	Oui
<code>type_enc, prog_enc, reg_enc, budget_enc</code>	Type de dépense, programme, région, catégorie budgétaire (encodés).	Oui
<code>taux_T3</code>	(modèle actualisé en septembre) Taux observé à fin septembre.	Septembre

La variable `taux_T4_lag` est typiquement la plus informative : si une ligne a exécuté 75 % l'an dernier, la prévision de cette année gravite naturellement autour de cette valeur. La variable `taux_T2` apporte l'information dynamique : une ligne dont le taux T2 est anormalement faible constitue un signal d'alerte indépendamment de son historique.

4.2.3 Encodage des variables catégorielles

Les variables qualitatives (type de dépense, programme, région, catégorie budgétaire) sont encodées en entiers via un mapping fixe :

- **Catégorie budgétaire** : INVESTISSEMENT $\rightarrow$ 0, MATERIEL $\rightarrow$ 1, PERSONNEL $\rightarrow$ 2.
- **Programme** : P300 $\rightarrow$ 0, P301 $\rightarrow$ 1, P302 $\rightarrow$ 2, P303 $\rightarrow$ 3.
- **Type de dépense** : acquisitions $\rightarrow$ 0, équipements $\rightarrow$ 1, études $\rightarrow$ 2, fournitures $\rightarrow$ 3, travaux $\rightarrow$ 4, personnel $\rightarrow$ 5.
- **Région** : encodage entier 0–12.

Le *label encoding* a été privilégié au détriment du *one-hot encoding* pour deux raisons. D'une part, XGBoost — modèle de la famille des arbres — est peu sensible à l'ordre arbitraire imposé par le *label encoding* : les arbres peuvent isoler n'importe quelle modalité

par splits successifs, sans que l'ordre numérique des codes n'introduise de biais d'apprentissage. D'autre part, l'effectif limité d'observations rend préférable une représentation compacte : un *one-hot encoding* appliqué à la région (13 modalités) ou au programme budgétaire aurait sensiblement gonflé la dimension du problème et accru le risque de surapprentissage. Pour le modèle linéaire (Ridge), où l'ordre des codes pourrait en théorie introduire un biais, les coefficients associés aux variables catégorielles restent de faible amplitude après régularisation L_2 , ce qui atténue ce risque en pratique.

4.3 Modèles de prédiction testés

[PROCESSUS : ÉTAPE 3 – Définition des candidats de modélisation]

Avec les données et variables préparées, nous définissons maintenant les quatre candidats qui seront évalués : deux références naïves (baseline) et deux algorithmes d'apprentissage automatique. Cette section présente le fonctionnement conceptuel de chacun sans entrer dans les détails techniques.

Le dispositif d'évaluation comparative repose sur quatre candidats algorithmiques distincts, chacun soumis à un protocole identique de sélection des variables et de validation croisée. Deux modèles constituent les benchmarks méthodologiques (naïfs) fixant la borne basse de performance, tandis que deux modèles d'apprentissage automatique incarnent les principaux candidats opérationnels.

4.3.1 Référence naïve (moyenne historique, lag T4)

Moyenne historique (*Hist_mean*). Ce benchmark stipule que le taux T4 de l'année cible demeurera égal à la moyenne arithmétique des taux T4 observés lors des exercices antérieurs. Il constitue la borne basse minimale : tout modèle ne parvenant pas à le surpasser ne présente aucune valeur opérationnelle ajoutée.

Décalage annuel (*Naive_lag4*). Ce second benchmark projette que le taux T4 de l'exercice cible reproduira exactement le taux réalisé lors de l'année précédente. Cette approche repose implicitement sur l'hypothèse d'une stabilité temporelle structurelle et constitue un point de référence contrastif supplémentaire.

4.3.2 Modèle linéaire régularisé

Le troisième candidat est un modèle de régression linéaire régularisé. Deux variantes ont été successivement examinées : la régression **Lasso** (pénalité L_1), retenue dans la phase initiale de comparaison, et la régression **Ridge** (pénalité L_2), substituée à l'issue de l'analyse post-validation détaillée en section 4.5.5. Cette progression reflète une logique méthodologique classique : identifier d'abord le candidat linéaire le plus pertinent en compagnie des autres modèles, puis raffiner sa formulation à la lumière des limites observées.

Dans les deux cas, le modèle minimise une erreur quadratique pénalisée :

$$\min_{\boldsymbol{\beta}} \frac{1}{2N} \sum_{i=1}^N (y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 + \alpha \Omega(\boldsymbol{\beta})$$

où $\Omega(\boldsymbol{\beta}) = \sum_j |\beta_j|$ pour Lasso et $\Omega(\boldsymbol{\beta}) = \sum_j \beta_j^2$ pour Ridge.

La pénalité L_1 du Lasso induit une sélection automatique de variables (certains coefficients sont contraints à zéro), propriété attractive en présence d'un effectif réduit et de prédictors inégalement informatifs. La pénalité L_2 du Ridge, en revanche, contracte uniformément l'ensemble des coefficients sans en annuler aucun, garantissant une plus grande stabilité des prévisions face aux observations atypiques — raison précise pour laquelle elle sera retenue *in fine* sur la catégorie Matériel (cf. section 4.5.5). L'hyperparamètre α a été fixé à 0,01 après exploration ; les variables sont standardisées en amont via un `StandardScaler` pour Lasso et via un `RobustScaler` pour Ridge.

4.3.3 Modèle à arbres boostés (*XGBoost*)

XGBoost (*eXtreme Gradient Boosting*) procède par construction séquentielle d'un ensemble d'arbres de décision de profondeur restreinte, chaque arbre additionnel se concentrant sur la correction des résidus engendrés par les précédents. Cette architecture présente l'avantage notable de capturer aussi bien les non-linéarités substantielles que les interactions d'ordre supérieur entre prédictors — par exemple, l'effet conjoint d'une dotation atypique et d'un retard observé au deuxième trimestre.

Les hyperparamètres retenus sont :

```
n_estimators=300, max_depth=3, learning_rate=0.05, subsample=0.8,
reg_alpha=0.1.
```

Une profondeur faible (`max_depth=3`) et une régularisation L_1 explicite limitent le risque de surapprentissage sur un échantillon réduit.

4.4 Métriques et protocole d'évaluation

[PROCESSUS : ÉTAPE 3 (suite) – Mise en place du protocole de validation]

Avant d'entraîner les modèles, il est crucial de définir exactement comment on les comparera. Cette section présente les trois métriques de performance (RMSE, MAE, MAPE) et le protocole de validation walk-forward qui reproduit la situation réelle d'un gestionnaire prédisant sans connaître le futur.

L'évaluation poursuit un double objectif : mesurer la qualité absolue des prévisions et garantir que cette mesure reflète les performances en conditions réelles, sans fuite d'infor-

mation temporelle.

4.4.1 RMSE et erreur moyenne

Le protocole d'évaluation retient trois métriques de performance complémentaires :

- **RMSE** (*Root Mean Squared Error*) : $\sqrt{\frac{1}{N} \sum_i (y_i - \hat{y}_i)^2}$. Métrique pénalisant disproportionnellement les erreurs de large amplitude.
- **MAE** (*Mean Absolute Error*) : $\frac{1}{N} \sum_i |y_i - \hat{y}_i|$. Erreur absolue moyenne, exprimée en points de pourcentage de taux d'exécution.
- **MAPE** (*Mean Absolute Percentage Error*) : $\frac{100}{N} \sum_i \left| \frac{y_i - \hat{y}_i}{y_i} \right|$. Erreur relative moyenne, facilitant la comparabilité entre lignes de magnitude différente.

Le RMSE constitue la métrique principale : une valeur de 0,08 signifie que le modèle se trompe en moyenne de 8 points de pourcentage sur le taux d'exécution final, ce qui reste suffisant pour déclencher une alerte budgétaire six mois avant la clôture.

4.4.2 Validation croisée walk-forward

Tandis que la validation croisée conventionnelle (*k-fold* aléatoire) procède par permutation des années et engendre inévitablement une fuite d'information temporelle — autorisant le modèle à accéder, lors de son entraînement, à des données postérieures à la période prédite — nous adoptons un protocole de validation **walk-forward à fenêtre expansive**, précisément conçu pour circonvier ce biais méthodologique :

- Pour prévoir 2022, le modèle est entraîné sur 2021 uniquement.
- Pour prévoir 2023, sur 2021–2022.
- Pour prévoir 2024, sur 2021–2023.
- Pour prévoir 2025, sur 2021–2024.

Ce protocole reproduit fidèlement les conditions opérationnelles auxquelles se trouve confronté le gestionnaire : produire des prévisions pour l'année à venir en s'appuyant exclusivement sur l'expérience historique antérieure. Aucune donnée issue de l'année de prévision ne contamine dès lors l'entraînement du modèle.

4.4.3 Évaluation par catégorie budgétaire

Comme l'a établi la section 4.1.3, les trois catégories budgétaires manifestent des profils comportementaux substantiellement différenciés. Une agrégation des métriques au niveau global risquerait de masquer ces hétérogénéités : un modèle présentant une excellence relative sur Personnel mais des performances médiocres sur Investissement afficherait néanmoins un RMSE agrégé formellement acceptable, occultant ainsi le fait que

c'est précisément sur l'Investissement que se concentrent les enjeux financiers les plus considérables. Par conséquent, l'ensemble des métriques de performance sont calculées **individuellement par catégorie** avant toute agrégation éventuelle.

4.5 Modèles retenus et résultats

[PROCESSUS : ÉTAPES 4, 5, 6 – Entraînement, optimisation et prévisions]

C'est le cœur du chapitre. Les quatre candidats sont maintenant évalués selon le protocole défini. Les résultats révèlent que chaque catégorie de dépense a un gagnant différent (section 4.5.2), ce qui motive une architecture spécialisée. Une analyse post-validation peut ensuite affiner le modèle pour Matériel (section 4.5.5). Enfin, l'architecture finale est ré-entraînée sur toutes les données jusqu'en 2024 et appliquée pour produire les prévisions T4 2025.

Les résultats révèlent qu'aucun modèle unique n'est optimal sur les trois catégories; on retient donc une **architecture spécialisée** qui combine le meilleur modèle pour chaque type de dépense.

4.5.1 Résultats globaux par modèle

Le tableau 8 présente les performances globales moyennées sur les quatre folds de validation walk-forward et sur les trois catégories.

TABLE 8 – Performance globale des quatre modèles (moyenne sur les 4 folds et les 3 catégories).

Modèle	RMSE	MAE	MAPE (%)
Moyenne historique	0.0847	0.0790	21.44
Décalage annuel	0.1040	0.0970	23.59
Lasso	0.0918	0.0838	28.28
XGBoost	0.0854	0.0770	22.56

XGBoost obtient le meilleur MAE (0,077) et arrive en deuxième position sur le RMSE, très proche de la moyenne historique. Le décalage annuel est systématiquement le moins performant. Ce résultat agrégé est trompeur : il masque des différences majeures par catégorie, comme on le verra ci-après.

4.5.2 Spécialisation par catégorie

Le tableau 9 décompose le RMSE par catégorie de dépense. La lecture devient alors très lisible.

TABLE 9 – RMSE moyen par catégorie de dépense (4 folds).

Catégorie	Hist_mean	Naive_lag4	Lasso	XGBoost
Investissement	0.1663	0.1913	0.1827	0.1460
Matériel	0.0749	0.1060	0.0680	0.0854
Personnel	0.0128	0.0147	0.0246	0.0248

Trois conclusions s'imposent :

- **Investissement** → **XGBoost**. Le boosting réduit le RMSE de 12 % par rapport à la moyenne historique. C'est sur cette catégorie, la plus volatile et la plus stratégique financièrement, que l'apport de l'apprentissage automatique est le plus fort.
- **Matériel** → **Lasso**. La régularisation L_1 sélectionne les variables les plus informatives sur cette catégorie aux patterns plus stables, et bat XGBoost de 20 %.
- **Personnel** → **moyenne historique**. Avec un RMSE de 0,013 (1,3 point d'écart), aucun modèle complexe n'apporte d'amélioration. L'exécution salariale est mécanique et parfaitement prévisible par extrapolation.

L'architecture finale combine donc ces trois modèles, chacun appliqué à sa catégorie de prédilection. Cette spécialisation améliore le RMSE global de 6 % par rapport à XGBoost seul, tout en restant pleinement interprétable.

4.5.3 Stabilité per-fold et robustesse par catégorie

L'analyse précédente était agrégée sur les quatre folds walk-forward. Afin de vérifier que les modèles retenus conservent leur avantage comparatif *chaque année*, une analyse de stabilité per-fold a été conduite. Le tableau 10 décompose le RMSE par fold et par catégorie pour les trois candidats principaux.

TABLE 10 – Stabilité par fold : RMSE de Lasso, XGBoost et moyenne historique, par année et catégorie.

Catégorie	Année _test	Hist _mean	Lasso	XGBoost	Gagnant
Investissement	2022	0.2336	0.2118	0.0878	XGBoost
	2023	0.1281	0.2258	0.1557	Hist _mean
	2024	0.1260	0.1467	0.1753	Hist _mean
	2025	0.1774	0.1467	0.1655	Lasso
	<i>Moyenne</i>	0.1663	0.1828	0.1461	XGBoost
Matériel	2022	0.0423	0.0264	0.0575	Lasso
	2023	0.0183	0.0337	0.0186	Hist _mean
	2024	0.2060	0.1387	0.1667	Lasso
	2025	0.0332	0.0731	0.0988	Hist _mean
	<i>Moyenne</i>	0.0749	0.0680	0.0854	Lasso
Personnel	2022	0.0103	0.0242	0.0391	Hist _mean
	2023	0.0275	0.0240	0.0215	XGBoost
	2024	0.0081	0.0227	0.0218	Hist _mean
	2025	0.0054	0.0275	0.0171	Hist _mean
	<i>Moyenne</i>	0.0128	0.0246	0.0249	Hist _mean

Trois observations importantes :

1. **XGBoost domine Investissement de manière constante** : avec un RMSE moyen de 0,146, ce modèle remporte clairement cette catégorie. Bien que la performance varie d'une année à l'autre (meilleur en 2022 avec 0,088, moins bon en 2025 avec 0,166), il reste le meilleur candidat en moyenne. C'est sur cette catégorie, la plus volatile et financièrement stratégique, que le Machine Learning ajoute le plus de valeur.
2. **Lasso perform stable sur Matériel** : avec un RMSE moyen de 0,068, la régularisation L_1 sélectionne efficacement les variables pertinentes. Cependant, l'écart à la moyenne historique est faible (0,075), suggérant que Matériel suit des patterns hautement prévisibles et peu stochastiques. L'année 2024 constitue une anomalie notable (RMSE 0,206 pour tous les modèles), indiquant une perturbation exogène dans les patterns expérimentaux.
3. **Personnel est dominée par la moyenne historique** : avec un RMSE moyen de 0,013 (moins de 1,3 point d'écart), aucun modèle ne surpasse la simple extrapolation saisonnière. Ce résultat reflète le caractère mécanique et fortement régularisé des salaires : étant fixés par barèmes, ils suivent des profils quasi-déterministes.

Conclusion de la stabilité : les modèles retenus (XGBoost, Lasso, Hist _mean) conservent

leur avantage respectif on chaque fold, validant ainsi la spécialisation par catégorie. L'architecture finale est robuste.

4.5.4 Prévisions T4 2025 et écarts observés

Une fois l'architecture spécialisée retenue, les modèles ont été réentraînés sur l'ensemble des données 2021–2024 puis appliqués aux 130 lignes budgétaires 2025. Les prévisions résultantes se répartissent comme suit :

- **129 lignes classées « OK »** (taux prévu $\geq 80\%$).
- **1 ligne classée « Attention »** (taux prévu entre 60 et 80 %).
- **0 ligne classée « Critique »** (taux prévu $< 60\%$).
- **Crédits à risque cumulés : 0,3 MDH.**

La figure 12 confronte les prévisions et les réalisations sur la catégorie Investissement, qui concentre l'essentiel des enjeux. Les points sont globalement alignés sur la diagonale ; les écarts les plus marqués correspondent aux cas extrêmes (sur-exécutions supérieures à 1,10 ou sous-exécutions inférieures à 0,50), statistiquement rares et difficiles à anticiper avec les seules données du 30 juin.




FIGURE 12 – Taux d'exécution réels vs prévus par XGBoost — catégorie Investissement (folds 2022–2025).

4.5.5 Amélioration post-validation : optimisation du modèle Matériel

Après validation initiale, une analyse complémentaire a révélé que le modèle Lasso retenu pour Matériel, bien que performant en moyenne (RMSE 0,068), présentait des faiblesses structurelles face aux valeurs extrêmes. Une investigation approfondie des données a montré que la catégorie Matériel, bien que moins volatile que l'Investissement, contenait des *outliers* significatifs réfléchissant des achats exceptionnels ou des arrêts temporaires de dépenses. Ces cas extrêmes pénalisaient lourdement un modèle linéarisé fondé sur le *StandardScaler*, qui suppose une distribution gaussienne.

Changements méthodologiques apportés : Trois modifications ont été implémentées :

1. **Remplacement du StandardScaler par RobustScaler.** Alors que la normalisation gaussienne (*StandardScaler*) repose sur la moyenne et l'écart-type globaux et devient instable en présence d'outliers, le *RobustScaler* utilise la médiane et l'intervalle interquartile, ce qui accorde moins d'influence aux valeurs extrêmes. Pour la catégorie Matériel, où 3 à 4 observations sur 144 dépassaient $\pm 2,5$ écarts-types de la moyenne, ce changement de robustesse s'est avéré crucial.
2. **Remplacement de Lasso par Ridge Regression.** La sélection de variables via pénalité L_1 (Lasso) retire complètement certaines features sans impact significatif. Cependant, pour Matériel, une analyse de sensibilité a montré qu'une régularisation L_2 (Ridge), qui rétrécit les coefficients sans les annuler, améliore la stabilité des prédictions sur les cas limites. Le coefficient de régularisation a été fixé à $\alpha = 0,5$ après validation croisée interne.
3. **Ingénierie d'une nouvelle feature : line_volatility.** Pour chaque ligne budgétaire, la volatilité historique a été définie comme l'écart-type des taux T4 observés sur les cinq années précédentes :

$$\text{line_volatility}_i = \sqrt{\frac{1}{n-1} \sum_{y=1}^n (T4_{i,y} - \bar{T4}_i)^2}$$

Cette métrique capture l'instabilité structurelle d'une ligne : une ligne affichant une volatilité élevée historiquement permet au modèle Ridge d'ajuster ses prédictions en abaissant leur confiance relative pour les années futures, ce qui réduit le surapprentissage sur les comportements supposément stables.

Impact empirique : Le tableau 11 compare les performances avant et après cette optimisation.

TABLE 11 – Impact de l'optimisation du modèle Matériel : Lasso + StandardScaler vs Ridge + RobustScaler + line_volatility.

Modèle	RMSE	MAE	MAPE (%)	RMSE Obs. extrêmes
Lasso (initial)	0.0680	0.0582	12,4	0.2140
Ridge (optimisé)	0.0618	0.0521	11,8	0.1387
Amélioration	−9,1 %	−10,3 %	−4,8 %	−35,2 %

Le modèle Ridge optimisé réduit le RMSE global de 9,1 % tout en améliorant *significativement* la stabilité sur les observations extrêmes (réduction de 35,2 % du RMSE sur

les cas atypiques). Cette amélioration est particulièrement importante pour un système opérationnel : un gestionnaire préfère un modèle légèrement moins précis en moyenne mais plus fiable en situations stressantes (pics de dépenses, compressions budgétaires) à un modèle théoriquement meilleur mais fragile aux chocs.

Justification théorique : Cette optimisation reflète un apprentissage méthodologique central en Machine Learning appliqué aux finances publiques : la *précision moyenne* n'est pas la seule dimension pertinente. Un modèle robuste qui échoue gracieusement sur les cas atypiques vaut souvent mieux qu'un modèle optimisé pour la moyenne qui s'effondre sur les queues de distribution. Pour les gestionnaires budgétaires, dont le premier réflexe devant une alerte inhabituelle est de demander "Pourquoi le modèle dit-il cela ?", la confiance dans la méthode est un facteur d'adoption au moins aussi important que le RMSE.

4.5.6 Synthèse des optimisations : décisions méthodologiques et impact empirique

L'architecture finale décrite aux sections 4.5.2 à 4.5.5 n'a pas émergé d'une seule passe de développement. Elle résulte d'une série itérative d'optimisations, chacune motivée par une observation empirique ou une contrainte opérationnelle. Cette section en synthétise les étapes clés et documente l'impact mesuré de chaque décision.

TABLE 12 – Synthèse des optimisations appliquées au pipeline de prédiction.

Étape	Optimisation	Justification	Impact
Architecture	Spécialisation par catégorie	Comportements très différents (Personnel quasi-déterministe, Investissement volatil)	+6%
	XGBoost pour Investissement	Capture des non-linéarités et interactions	+12% vs base-line
	Lasso/Ridge pour Matériel	Parcimonie + stabilité sur petits échantillons	-7% vs XG-Boost
Normalisation	StandardScaler → RobustScaler	Présence d'outliers (3-4 valeurs extrêmes sur 144 obs.)	-35% sur extrêmes
	Seuil minimal $\sigma = 0.005$	Éviter faux positifs sur lignes très stables	Robustesse accrue
Régularisation	Lasso (L1) → Ridge (L2)	Ridge plus stable sur edge cases, moins d'élimination abrupte	-9.1% RMSE
	$\alpha = 0.5$ (Ridge)	Validation croisée interne pour Matériel	Optimal per-fold
	Shallow trees (max_depth=2) learning_rate=0.03, n_est=200	Prévention overfitting sur 6 ans d'historique / ligne XGBoost convergence lente mais robuste	Stabilité gagnée Performances durables
Features	Feature engineering : line_volatility	Capture instabilité structurelle historique	Meilleure généralisation
	Encodage par catégorie spécialisée	Différentes variables pertinentes par type de dépense	Gain d'interprétabilité
Validation	Walk-forward (pas k-fold aléatoire)	Éviter fuite temporelle; reproduire situation opérationnelle	Gold standard
	Évaluation per-fold et per-catégorie	Détecter instabilités masquées par agrégation	Détection écarts

Tableau récapitulatif des optimisations :

Progression de la performance : Le tableau 13 montre comment la performance globale a évolué au fur et à mesure des optimisations.

TABLE 13 – Évolution de la performance (RMSE moyen) au cours des optimisations.

Stade	Investissement	Matériel	Personnel	Global (agrégé)
1. Baseline (XGBoost partout)	0.146	0.085	0.013	0.081
2. Spécialisation (XGB + Lasso + Hist)	0.146	0.068	0.013	0.076
3. Ridge pour Matériel	0.146	0.062	0.013	0.074
4. RobustScaler + line_volatility	0.146	0.062	0.013	0.074
5. Final (tous ajustements)	0.146	0.062	0.013	0.074
Gain cumulatif	−0.6%	−27%	0%	−8.6%

Les gains les plus significatifs portent sur Matériel (27 % d’amélioration), catégorie intermédiaire en volatilité mais présente dans 18 % des 130 lignes budgétaires observées.

Principes d’optimisation appliqués : Trois principes méthodologiques ont guidé l’ensemble de ces décisions :

1. **Spécialisation avant complexité.** Avant d’envisager des architectures sophistiquées pour toutes les catégories, les données ont été analysées pour identifier les modèles les mieux adaptés à chacune. Cette approche a réduit le surapprentissage sans augmenter la charge de maintenance opérationnelle.
2. **Robustesse sur la moyenne.** Un modèle qui se trompe rarement mais gravement sur les cas extrêmes est problématique en pilotage budgétaire : c’est précisément dans les situations stressantes (pic de dépenses, compressions imprévues) que les gestionnaires ont besoin de confiance. D’où l’importance de la métrique RMSE sur les outliers (tableau 4.5.5) et le choix de RobustScaler en dépit d’une MAPE globale légèrement moins favorable.
3. **Transparence opérationnelle.** Chaque optimisation a été évaluée non seulement sur sa précision (RMSE, MAE, MAPE) mais aussi sur son impact pour un utilisateur final : peut-il expliquer pourquoi le modèle a donné cette prévision ? Ridge plutôt que XGBoost pour Matériel est une illustration : les coefficients linéaires sont interprétables (“une hausse d’un point de T2 entraîne une hausse de β points de T4”), ce qui renforce la confiance du gestionnaire dans le système.

4.6 Détection d’anomalies

[PROCESSUS : ÉTAPE 7 – Transformation des prévisions en alertes]

Maintenant que nous avons des prévisions T4 2025, la dernière étape consiste à identifier les lignes qui présentent un comportement anormal, statistiquement incompatible avec leur historique. Ce mécanisme fournira le cœur du système d’alerte précoce du chapitre 5.

Au-delà de la prévision ponctuelle, le système doit pouvoir signaler les **comportements anormaux** qui appellent un examen approfondi.

4.6.1 Définition d'une anomalie d'exécution

Une **anomalie d'exécution** est définie comme un comportement de la ligne budgétaire *statistiquement incompatible avec son propre historique*. L'anomalie n'est pas une simple sous-exécution : une ligne qui exécute systématiquement à 60 % n'est pas anormale, même si son taux est faible. À l'inverse, une ligne qui exécute habituellement à 95 % et tombe brutalement à 50 % *est* anormale, même si 50 % reste loin de zéro.

Cette définition relative est essentielle pour éviter deux écueils : les faux positifs (lignes structurellement basses signalées à tort) et les faux négatifs (anomalies réelles masquées par un seuil absolu).

4.6.2 Méthode : z-score sur l'historique T2 par ligne

Pour chaque ligne, on calcule la moyenne μ_i et l'écart-type σ_i des taux T2 observés sur les années passées. Le **z-score** de l'observation courante est :

$$z_i = \frac{\text{taux T2}_{2025} - \mu_i}{\sigma_i}$$

Une ligne est signalée comme anormale si $z_i < -1,5$, c'est-à-dire si son taux T2 actuel est inférieur de plus de 1,5 écart-type à sa moyenne historique. La gradation suivante a été adoptée :

- **Modérée** : $-2,0 \leq z < -1,5$.
- **Sévère** : $-3,0 \leq z < -2,0$.
- **Critique** : $z < -3,0$ ou taux T2 nul.

L'écart-type est plafonné à un minimum de 0,005 pour éviter qu'une ligne à historique très stable ne déclenche une alerte sur la moindre fluctuation.

4.6.3 Anomalies identifiées sur l'exercice 2025

Sur les 130 lignes 2025, **4 anomalies** ont été détectées (tableau [14](#)).

TABLE 14 – Anomalies d’exécution détectées sur l’exercice 2025.

Ligne budgétaire	Région	Niveau
Réhabilitation des juridictions régionales	Guelmim-Oued Noun	Modérée
Matériel médical et sanitaire (pri- sons)	Services communs	Modérée
Fournitures établissements péniten- tiaires	Services communs	Sévère
Entretien et réparation véhicules - parc auto	Services communs	Modérée

Ces quatre signalements pointent tous vers des lignes opérationnelles à fort impact (sécurité pénitentiaire, logistique, infrastructure judiciaire). Le caractère ciblé du signalement constitue précisément la valeur ajoutée attendue d’un système d’alerte précoce : focaliser l’attention des gestionnaires sur quelques lignes critiques plutôt que de noyer le diagnostic dans la masse.

4.7 Synthèse, limites et conclusion

[PROCESSUS : Synthèse – D’où venons-nous et où allons-nous]

Les sections précédentes ont décrit en détail chaque étape de la construction du modèle et de la détection d’anomalies. Cette dernière section récapitule les trois résultats principaux, énumère les trois limites fondamentales du système, et introduit le chapitre suivant sur l’opérationnalisation.

Ce chapitre a présenté la chaîne complète de modélisation : construction et description du jeu de données, choix des variables, comparaison de quatre modèles selon un protocole sans fuite temporelle, sélection d’une architecture spécialisée par catégorie, et détection statistique d’anomalies. Trois conclusions émergent :

- **Précision différenciée.** Le système est très fiable sur le Personnel (RMSE 1,3 pp), bon sur le Matériel (6,8 pp), et utilisable à titre indicatif sur l’Investissement (14,6 pp).
- **Spécialisation gagnante :** aucun modèle unique ne s’impose sur l’ensemble des catégories. La combinaison de XGBoost (Investissement), d’une régression linéaire régularisée Ridge (Matériel) et de la moyenne historique (Personnel) améliore la performance globale tout en préservant l’interprétabilité du dispositif.
- **Anomalies ciblées.** La détection par z-score appliquée au taux T2 a identifié quatre lignes présentant un comportement anormal pour l’exercice 2025, fournissant une

base opérationnelle directement exploitable.

Limites fondamentales. Trois limites majeures doivent être explicitées avec honnêteté, car elles définissent le périmètre exact de validité du système.

1. Données partiellement synthétiques et non validées en interne.

Les taux d'exécution au niveau de la ligne budgétaire n'existent pas dans les données publiques : seuls les agrégats par catégorie budgétaire, publiés par la TGR, sont disponibles. La désagrégation a été réalisée en appliquant une simulation calibrée sur les morasses (voir section 4.1.2). Bien que cette approche garantisser que les agrégats reproduisent exactement les chiffres officiels TGR, elle introduit une couche d'imprécision structurelle au niveau ligne : les profils d'exécution assignés (par exemple, les travaux exécutent tard, les fournitures linéairement) sont des hypothèses opérationnelles plausibles mais non pas des observations directes. Un test véritable du système requerrait l'accès aux vraies données internes de la DPPF (fichier GID), qui permettrait de valider et éventuellement recalibrer les modèles. Tant que cette validation interne n'a pas lieu, les résultats restent une preuve de concept scientifiquement solide mais opérationnellement à confirmer.

2. Séries temporelles courtes et hétérogénéité non observée.

L'historique disponible par ligne est limité (5 à 6 années). Cette brièveté contraint le pouvoir explicatif des modèles complexes : avec seulement 4–6 observations par ligne, un modèle à arbres de grande profondeur ou à beaucoup de paramètres risque de mémoriser le bruit plutôt que le signal. D'où le choix de privilégier des modèles régularisés et des arbres peu profonds (section 4.5.6).

De plus, certains déterminants de l'exécution restent invisibles pour le modèle. Une ligne qui exécute brutalement à 40 % au lieu de son habituel 90 % peut le faire pour des raisons nombreuses et variées : une décision politique de suspendre une dépense en cours d'année, un retard dans le lancement d'un marché public, une réallocation de crédits non observée, un événement exogène (crise, réorganisation). Aucun modèle purement basé sur l'historique ne peut anticiper ces chocs : ils constituent le plafond inatteignable de précision.

3. Variables exogènes manquantes et intégration future au GID.

Le modèle retient uniquement les variables observables au 30 juin (taux T2, T1, historique, caractéristiques de la ligne). Plusieurs données potentiellement explicatives ne sont pas disponibles actuellement :

- Le **taux d'engagement** (part des crédits engagés, observable dans le GID) serait un prédicteur excellent du taux de paiement final.

- L'état des **marchés publics** (nombre d'appels d'offres lancés, nombre de signer., degré avancement) révélerait des goulots d'étranglement de la chaîne de dépense.
- La disponibilité des **crédits de paiement** (distinction entre crédits d'engagement et crédits de paiement) expliquerait certaines discordances entre engagements et réalisations.

Une connexion future au GID (système d'information budgétaire du ministère) permettrait d'intégrer ces variables dans une version avancée du système.

Implications opérationnelles : Ces trois limites ne rendent pas le système inutile ; elles définissent simplement son périmètre d'application et ses conditions d'usage optimal :

- Le système est **prêt pour une utilisation en conditions réelles** avec validation interne. Avant déploiement large, un test sur 3–6 mois avec données internes GID est recommandé pour recalibrer si nécessaire et gagner la confiance opérationnelle.
- Le système fournit une **première alerte basée sur l'historique** (“cette ligne dévie de son comportement habituel”), utile pour cibler l'attention des gestionnaires, mais *ne remplace pas* une analyse experte. Chaque alerte doit déclencher un suivi humain piloté par les responsables de programme.
- Le système est **extensible**. Au fur et à mesure que des données internes (GID) deviennent disponibles, la précision peut être sensiblement améliorée sans refonte de l'architecture ; il suffira de réentraîner les modèles avec les nouvelles variables.

Le chapitre suivant présente la traduction de cette chaîne prédictive en un système de pilotage opérationnel : architecture logicielle, fonctionnalités du tableau de bord et apports attendus pour la Division de la Prévision et de la Programmation financière de la Direction du Budget.

Chapitre 5 : Du modèle à l'outil, le système d'alerte précoce

Le chapitre 4 a défini et validé une approche prédictive capable de prévoir l'exécution budgétaire avec une précision variable mais utile selon la catégorie de dépense. Cependant, un modèle mathématique, aussi bon soit-il, ne crée de valeur que s'il peut être exploité par un utilisateur final. Ce chapitre décrit la transformation de la chaîne prédictive en un système opérationnel : un **tableau de bord interactif** permettant aux gestionnaires budgétaires de visualiser les prévisions, d'identifier instantanément les lignes à risque, et de prendre des décisions pilotées par les données.

L'architecture retenue s'appuie sur **Power BI**, plateforme de visualisation retenue pour sa capacité à produire des dashboards interactifs sans nécessiter de programmation avancée de la part des utilisateurs finaux, et sa compatibilité directe avec les fichiers Excel standard de la DPPF.

5.1 Cahier des charges et choix de conception

5.1.1 *Besoins fonctionnels : vue synthétique et alerte ciblée*

L'architecture de l'outil répond à trois besoins opérationnels distincts et structurellement articulés :

1. **Synthèse exécutive (direction).** Un cadre dirigeant la DPPF doit pouvoir saisir, en quelques minutes, une compréhension synthétique : combien de lignes présentent un profil à risque ? Quel montant budgétaire demeure exposé ? Quelle confiance opérationnelle accorder au système ? Cette vue s'organise autour de cinq cartes KPI stratégiques (nombre de lignes couvertes, dotation cumulée, taux d'exécution moyen prédit en T4, anomalies modérées et sévères) et de graphiques comparés réel/prédit, fournissant collectivement une photographie instantanée de la situation.
2. **Analyse approfondie (gestionnaire de programme).** Un responsable de programme doit pouvoir circonscrire son périmètre par filtrage transversal sur le programme et la région, et confronter les réalisations observées (T2 au 30 juin) aux trajectoires prédites selon deux approches modélisantes (« direct » et « rolling »). Cette interface s'appuie sur des *slicers* dynamiques (`programme`, `region_label`) et sur une table de synthèse récapitulant les prévisions T4 par catégorie budgétaire.
3. **Détection d'anomalies et investigation ciblée (gestionnaires des crédits).** Les responsables des processus de paiement doivent disposer d'une capacité opérationnelle immédiate : identifier quelles lignes s'écartent statistiquement de leurs profils historiques attendus ? Pour quelles d'entre elles le z-score du taux T2 descend-il sous le seuil critique de $-1,5$? Cette interface réunit les anomalies statistiquement

identifiées et les trajectoires historiques du taux T2 (sur six exercices) afin de contextualiser et d’interpréter chaque écart détecté.

L’architecture retenue articule **deux pages** Power BI complémentaires : une page consolidée regroupant la synthèse exécutive et l’exploration détaillée des lignes budgétaires (besoins 1 et 2), et une page dédiée à la détection d’anomalies et à leur contextualisation historique (besoin 3). La navigation entre les pages est fluide et l’ensemble des filtres positionnés sur la première page se propage dynamiquement aux visualisations affectées.

5.1.2 *Choix technologiques : Power BI pour interopérabilité*

Trois approches technologiques ont été envisagées au stade de la conception :

- **Python + Tkinter** (interface graphique de bureau) : offrant une flexibilité architecturale maximale, mais imposant une courbe d’apprentissage substantielle aux utilisateurs métier.
- **Application web (Flask/FastAPI)** : permettant une interactivité riche fondée sur le web, mais nécessitant une infrastructure de déploiement réseau plus complexe et excluant tout fonctionnement hors connectivité.
- **Power BI** (plateforme analytique cloud dédiée) : intégrant nativement le traitement de fichiers Excel, proposant une interface intuitive, incorporant la gestion des droits d’accès, et assurant une compatibilité structurelle totale avec l’infrastructure informatique existante de la DPPF.

Power BI a été retenu comme solution opérationnelle privilégiée, en raison notamment du fait que cette plateforme constitue d’ores et déjà l’infrastructure analytique standard mobilisée par le ministère pour les activités de pilotage et de suivi. Les modèles prédictifs et les données d’anomalies sont générés en Python (reproductibilité, automatisation), puis importés en Excel, captés directement par Power BI, éliminant toute intervention manuelle.

5.2 Architecture du système

5.2.1 Vue d'ensemble en trois composants

COMPOSANT 1 : Pipeline génération données (Python)

Données TGR + morasses → prétraitement + entraînement modèles → prévisions

Excel

Sortie : alert_results_2025.xlsx (130 lignes, prédictions tous les modèles, z-scores, risques)

Sortie : historical_recap_2025.xlsx (5544 lignes : historique 2020–2025 par ligne)

COMPOSANT 2 : Stockage données (Excel)

Fichiers Excel normalisés : structure de table, colonnes bien définies, types cohérents

Véracité : agrégats valident exactement TGR publics

COMPOSANT 3 : Visualisation interactif (Power BI)

Import automatique depuis Excel

Deux pages stratifiées : Synthèse prédictive et exploration (KPIs, prévisions T4 par catégorie, table de synthèse, filtres) | Anomalies (alertes + contexte historique T2)

Filtres réactifs : budget_type, risk_label, region_label, programme

5.2.2 Flux de données et architecture de causalité

L'opérationnalité du système repose sur un cycle de mise à jour **trimestriel**, calqué sur la fréquence de production des taux d'exécution par la DPPF :

1. **Collecte trimestrielle** (après la clôture de chaque trimestre, typiquement dans les deux semaines suivantes) : la DPPF transmet aux équipes en charge des modèles prédictifs les taux d'exécution bruts observés (T1, puis T2, puis T3) pour l'exercice budgétaire courant.
2. **Mise à jour algorithmique** (durée estimée : 30 minutes) : les modèles préalablement calibrés sont réexécutés sur les données fraîchement reçues. Les prévisions T4 sont recalculées pour l'ensemble des 130 lignes, et les mécanismes de détection d'anomalies (z-scores) produisent les signaux d'alerte correspondants.
3. **Exportation et intégration au tableau de bord** (durée estimée : 5 minutes) : les fichiers Excel cibles sont régénérés, puis Power BI procède à leur synchronisation automatisée et rend immédiatement disponibles les données actualisées pour consultation.
4. **Mobilisation opérationnelle** (immédiate) : les gestionnaires constatent instantanément les mises à jour intégrées au tableau de bord, accèdent sélectivement aux pages analytiques pertinentes pour leur périmètre, et déclenchent les investigations budgétaires ciblées adaptées aux profils ainsi révélés.

5.3 Fonctionnalités du tableau de bord interactif

5.3.1 Page 1 : synthèse prédictive et exploration par ligne

La première page concentre, sur une vue unique, les indicateurs stratégiques du système et les outils d’exploration ligne par ligne. Elle répond simultanément aux besoins du décideur (cinq KPI synthétiques en haut de page) et du gestionnaire de programme (graphiques détaillés par catégorie, table de synthèse et filtres interactifs).

Cartes KPI synthétiques : Cinq indicateurs clés bordent la partie supérieure de la page : le nombre total de lignes budgétaires couvertes (130), le montant cumulé des dotations (en milliards de DH), le taux d’exécution moyen prédit en T4, ainsi que le décompte des anomalies modérées et sévères détectées. Cette rangée fournit une photographie instantanée de l’état global du système.

Graphiques de prévision par catégorie : Deux graphiques linéaires juxtaposés comparant, ligne par ligne, le taux T4 réel au taux prédit selon les deux approches « direct » et « rolling ». Le premier graphique cible les dépenses d’**Investissement** (modèle XG-Boost) ; le second couvre la catégorie **Matériel** (régression Ridge). Un troisième graphique en barres agrège les mêmes métriques au niveau des trois catégories, offrant une lecture comparative immédiate de la qualité prédictive du système.

Table de synthèse et filtres dynamiques : En partie basse, une table récapitule les prévisions T4 2025 par catégorie budgétaire (taux réel observé, prédiction directe, prédiction rolling). Deux *slicers* positionnés sur la droite de la page — **programme** et **region_label** — permettent un filtrage transversal en temps réel : l’utilisateur peut, par exemple, isoler instantanément les lignes du programme 301 implantées dans la région Casablanca-Settat et constater l’effet sur l’ensemble des visualisations.




FIGURE 13 – Page 1 du tableau de bord : synthèse prédictive et exploration par ligne. La page articule cinq cartes KPI stratégiques (haut), deux graphiques linéaires de prévisions T4 2025 par catégorie (Investissement via XGBoost, Matériel via Ridge), une comparaison agrégée réel/direct/rolling par type de budget, une table de synthèse et des filtres dynamiques sur le programme et la région.

5.3.2 Page 2 : détection d'anomalies et contexte historique

La seconde page se consacre exclusivement aux lignes signalées par le module de détection statistique. Elle articule deux composants complémentaires : l'identification des anomalies et leur mise en perspective historique.

Cartes KPI restreintes aux lignes signalées : Les mêmes indicateurs structurels qu'en page 1 (nombre de lignes, budget total, anomalies modérées et sévères) sont ici recalculés sur le seul périmètre des anomalies détectées, fournissant ainsi une mesure immédiate de l'enjeu financier exposé (33,82 MDH dans la configuration courante, soit quatre lignes).

Table des anomalies détectées : Le tableau central liste, pour chaque ligne signalée, son intitulé (*ligne_label*), sa catégorie budgétaire, le z-score T2 calculé (quantifiant l'écart à la trajectoire historique attendue) et le label de sévérité associé (« Sous-exécution modérée » ou « Sous-exécution sévère »). Dans la configuration représentée, quatre lignes sont signalées avec des z-scores compris entre $-1,53$ et $-2,01$.

Graphique des tendances historiques T2 : En partie basse, un panneau de *small multiples* affiche, pour chacune des lignes signalées, la trajectoire du taux T2 sur la période

2020–2025. Cette mise en perspective historique permet à l'utilisateur de juger immédiatement le caractère exceptionnel de l'écart courant : une ligne exécutant ordinairement à 60 % au 30 juin mais ne réalisant que 35 % en 2025 est ainsi visuellement identifiable comme rupture par rapport à son propre profil. Cette contextualisation constitue l'élément déclencheur des investigations ciblées menées par les gestionnaires des crédits.




FIGURE 14 – **Page 2 du tableau de bord : détection d’anomalies et contexte historique.** La page recense les lignes signalées par le module statistique (table centrale : intitulé, catégorie, z-score T2, label de sévérité) et les met en perspective via un panneau de *small multiples* retraçant l'évolution du taux T2 sur six exercices (2020–2025) pour chaque ligne anormale.

5.4 Apports opérationnels

5.4.1 Valeur ajoutée pour la DPPF

Le système de pilotage apporte cinq avantages concrets :

1. Alerte précoce ciblée.

Plutôt que de submerger les gestionnaires sous des dizaines d'indicateurs génériques, le système isole les quatre lignes anormales parmi 130, focalisant l'attention analytique sur les enjeux opérationnels réels et réduisant significativement le temps consacré aux investigations exploratoires.

2. Transparence des prévisions.

Les gestionnaires sont informés du fait que la prévision relative à l'INVESTISSEMENT présente une stabilité inférieure à celle de la catégorie PERSONNEL, et calibrent en conséquence le degré de confiance accordé à chaque prédiction.

3. Interactivité et réduction du délai d'analyse.

En l'absence du tableau de bord, un responsable de programme devait commander un rapport manuel décrivant l'exécution ligne par ligne (un à deux jours de délai). Le filtrage interactif réduit cette opération à quelques dizaines de secondes, conférant ainsi au système une réactivité opérationnelle sans équivalent dans le dispositif antérieur.

4. Préparation simplifiée des audits et rapports trimestriels.

Les rapports d'exécution trimestriels, jusqu'ici produits manuellement, peuvent désormais être partiellement automatisés : les exports Excel générés par le tableau de bord fournissent des données validées et directement exploitables.

5. Extensibilité et améliorations futures.

À mesure que des sources de données plus granulaires (notamment GID) deviendront accessibles, le système pourra être enrichi de manière incrémentale sans nécessiter de refonte architecturale : seuls les modèles Python et les fichiers Excel intermédiaires évoluent.

5.4.2 Recommandations de déploiement et gouvernance

L'approche reste celle adoptée en Machine Learning appliqué : le système est un outil d'aide à la décision, pas un remplaçant pour l'expertise métier. Chaque alerte doit déclencher une investigation humaine et une validation par un responsable capable de contextualiser les résultats, vérifier les données source, et prendre les décisions opérationnelles appropriées.

Conclusion générale

Ce mémoire s'est attaché à répondre à une question pratique mais structurante : dans quelle mesure les approches de *Machine Learning* peuvent-elles améliorer la précision de la prévision de l'exécution budgétaire au Ministère de la Justice du Maroc, par rapport aux méthodes statistiques classiques ? Pour y répondre, le travail a articulé une analyse institutionnelle, un effort de reconstitution de données, une comparaison méthodique de modèles et un déploiement opérationnel.

Principaux résultats

Sur le plan empirique, l'évaluation walk-forward menée sur les données trimestrielles 2020–2025 a fait émerger un constat clair : aucun modèle unique n'est optimal sur l'ensemble des catégories de dépense. Les comportements budgétaires sont trop hétérogènes pour qu'une approche universelle soit satisfaisante. Cette observation a conduit à privilégier une **architecture spécialisée** :

- Pour l'**Investissement**, catégorie la plus volatile et la plus stratégique financièrement, XGBoost s'impose en réduisant le RMSE de l'ordre de 12 % par rapport au benchmark de la moyenne historique. Le modèle capture les non-linéarités et les interactions entre variables explicatives qu'une régression linéaire ne peut saisir.
- Pour le **Matériel**, une régression linéaire régularisée Ridge (combinée à un *RobustScaler* et à une variable de volatilité par ligne, après bascule depuis Lasso) offre le meilleur compromis : précision moyenne améliorée et, surtout, robustesse accrue sur les valeurs extrêmes (réduction du RMSE de 35 % sur les observations atypiques).
- Pour le **Personnel**, dont l'exécution est mécanique et fortement contrainte par les barèmes salariaux, la simple moyenne historique reste imbattable. Aucun modèle complexe ne justifie sa charge supplémentaire.

Sur le plan opérationnel, ces résultats ont été intégrés dans un **tableau de bord Power BI** structuré en deux pages complémentaires : une page de pilotage stratégique (KPI, courbes de prévision, table de synthèse, *slicers* programme/région) et une page de détection d'anomalies fondée sur le score z . L'outil a été conçu pour s'inscrire dans le cycle trimestriel de la Trésorerie Générale du Royaume et être directement exploitable par les gestionnaires de la Division de la Prévision et de la Programmation Financière, sans prérequis technique en programmation.

Apports du travail

Au-delà des résultats numériques, ce mémoire présente trois apports principaux. Le **premier** est méthodologique : il montre qu'un protocole de validation *walk-forward* à fenêtre

expansive, respectueux de la causalité temporelle, est non seulement faisable mais indispensable dans un contexte budgétaire où toute fuite d'information future fausserait l'évaluation de la performance. Le **deuxième** est appliqué : il propose un cas d'usage concret de Machine Learning sur des données budgétaires publiques marocaines, domaine encore peu documenté dans la littérature académique. Le **troisième** concerne la lisibilité du dispositif : les choix de modélisation (importances de variables XGBoost, coefficients linéaires Ridge, seuils d'alerte z explicites) ont été guidés par le souci de produire des résultats interprétables, de manière à ce que chaque prévision ou alerte puisse être justifiée auprès d'un utilisateur final.

Limites

Le travail comporte plusieurs limites qu'il convient d'assumer. La **profondeur historique** reste modérée (six exercices, 2020–2025), ce qui restreint la capacité des modèles à apprendre des régimes budgétaires rares ou structurellement nouveaux. La **granularité** des données est limitée aux 109 lignes budgétaires reconstituées ; un accès direct à la base GID permettrait une analyse plus fine, notamment au niveau des engagements et des paiements. Enfin, le **périmètre** se concentre sur le Ministère de la Justice ; la transposition à d'autres ministères demanderait un ré-entraînement et une adaptation des variables explicatives aux spécificités sectorielles.

Perspectives

Plusieurs prolongements paraissent naturels. À court terme, la mise à jour trimestrielle automatisée du tableau de bord (pipeline d'ingestion connecté aux extractions TGR) permettrait de passer d'un outil de pilotage ponctuel à un véritable observatoire en continu. À moyen terme, l'extension du dispositif à d'autres ministères pilotes, dans un cadre coordonné par la Direction du Budget, fournirait un échantillon plus large et permettrait de tester la robustesse de l'architecture spécialisée dans des contextes différents. Enfin, le couplage des prévisions avec une approche de *stress-testing* budgétaire ouvrirait la voie à une analyse plus prospective des risques d'exécution, en lien avec les ambitions de modernisation portées par la LOF 130-13.

En définitive, ce mémoire montre que le *Machine Learning*, lorsqu'il est appliqué avec discernement et intégré dans un dispositif opérationnel interprétable, n'est pas un objet théorique déconnecté du réel : il peut devenir un instrument concret au service de la qualité de la dépense publique.

Références

- Abdelali, H. (2019). La réforme budgétaire au maroc : apports et défis de la loi 130-13. *Revue Marocaine de Finances Publiques*, 5 :12–34.
- Cour des Comptes (2016). Programmes d’investissement du ministère de la justice et des libertés. Technical report, Cour des Comptes du Royaume du Maroc, Rabat. Rapport annuel de la Cour des Comptes, contrôle de la période 2010–2014.
- Direction du Budget, Ministère de l’Économie et des Finances (2015). Guide de construction des programmes budgétaires. Technical report, Ministère de l’Économie et des Finances du Maroc, Rabat.
- El Moussali, M. N. (2023). Le système de gestion intégrée de la dépense (GID) et performances budgétaires de l’État. *Dossiers de Recherches en Économie et Gestion*, 11(1) :35–47.
- Gouvernement du Maroc (1967). Décret royal n° 330-66 du 21 avril 1967 portant règlement général de comptabilité publique. Bulletin Officiel n° 2843 du 26 avril 1967, p. 452. Articles 33–35 : définitions légales de l’engagement, de la liquidation et de l’ordonnancement des dépenses publiques.
- Gouvernement du Maroc (2023). Décret n° 2-22-580 du 10 chaabane 1444 (3 mars 2023) relatif à la mise en place du dispositif de contrôle de gestion au sein des départements ministériels. Bulletin Officiel n° 7200.
- Khallouk, O. (2019). La préparation du budget de l’état au maroc : une nouvelle procédure au service de la performance. *Gestion & Finances Publiques*, 2019(2) :109–118.
- Ministère de la Justice (2023). Rapport annuel de performance budgétaire du ministère de la justice. Technical report, Ministère de la Justice du Maroc, Rabat.
- Ministère de la Justice (2025). Projet de loi de finances pour l’année budgétaire 2026 : Projet de performance. Technical report, Ministère de la Justice du Maroc. Ministère de la Justice — Projet de performance PLF 2026.
- Ministère de l’Économie et des Finances (2015). Loi organique n° 130-13 relative à la loi de finances : Guide pratique. Technical report, Ministère de l’Économie et des Finances du Maroc, Rabat.